

Evaluación Responsable de Sistemas Multimodales

Métricas, Reproducibilidad, Winoground, Ablación y Calibración

Material de lectura para el curso MCC225

IA Generativa y Aprendizaje Multimodal

Índice

1. Propósito del documento	2
2. Contexto académico de MCC225	3
3. Problema central de la evaluación multimodal	3
3.1. Más allá de una métrica única	3
3.2. Benchmarks frente a evaluación propia	4
4. Taxonomía mínima de tareas multimodales	4
5. Métricas para sistemas multimodales	5
5.1. Métricas automáticas	5
5.2. Métricas humanas y rúbricas	5
5.3. LLM-as-a-judge	5
6. Winoground y razonamiento composicional	5
6.1. Qué mide Winoground	5
6.2. Scores básicos	5
6.3. Uso recomendado en MCC225	6
7. Reproducibilidad experimental	6
7.1. Reproducibilidad como parte de la evaluación	6
7.2. Configuración mínima	6
7.3. Checklist de trazabilidad	7
8. Análisis de error	7
8.1. Por qué el análisis de error es obligatorio	7
8.2. Matriz de errores	7
8.3. Severidad	8
9. Estudios de ablación	8
9.1. Idea principal	8
9.2. Ablaciones recomendadas	8
10. Calibración	9
10.1. Qué significa calibrar	9
10.2. ECE y Brier score	9
10.3. Uso práctico en MCC225	9
11. Robustez y pruebas de confiabilidad	9
11.1. Robustez	9
11.2. Pruebas mínimas	9

12.Confiabilidad, sesgo y uso responsable	10
12.1. Confiabilidad	10
12.2. Sesgo	10
12.3. Ficha mínima de uso responsable	10
13.Explicabilidad e interpretabilidad	10
13.1. Explicar no es racionalizar	10
13.2. Criterios de interpretabilidad	10
14.Agentes multimodales y seguridad	11
14.1. Arquitectura agentic	11
14.2. Riesgos de inyección multimodal	11
14.3. Controles de seguridad	11
15.Comunicación responsable de resultados	11
15.1. Qué debe comunicarse	11
15.2. Frases aceptables y no aceptables	11
16.Criterios mínimos de calidad experimental	12
17.Ejemplo de pipeline experimental para MCC225	12
17.1. Escenario	12
17.2. Fases	13
18.Errores conceptuales frecuentes	13
18.1. Confundir demo con evaluación	13
18.2. Reportar solo el mejor resultado	13
18.3. Usar métricas incompatibles con la tarea	13
18.4. Omitir el post-procesamiento	13
18.5. Ignorar alucinaciones	13
18.6. Declarar confiabilidad sin calibración ni límites	13
19.Producto esperado para el estudiante	13
20.Ruta conceptual final	14
21.Conclusión	14
A. Glosario breve	14

1. Propósito del documento

Este documento presenta una lectura técnica para MCC225 sobre evaluación responsable de sistemas multimodales. El foco no está en entrenar un modelo nuevo, sino en determinar si un sistema que combina texto, imagen, audio, video, OCR, recuperación o herramientas fue evaluado con suficiente rigor para sostener una afirmación académica.

La idea principal es que un modelo multimodal no debe declararse confiable solo porque produce salidas plausibles. Debe evaluarse con métricas coherentes, configuración reproducible, análisis de error, discusión de limitaciones, estudios de ablación, calibración, pruebas de robustez y criterios explícitos de comunicación responsable.

El objetivo pedagógico es que el estudiante pueda:

1. distinguir entre una demostración visual y una evaluación experimental,
2. seleccionar métricas compatibles con la tarea multimodal,
3. documentar datos, prompts, modelo, versión, semillas y salidas crudas,
4. clasificar errores por tipo, severidad y modalidad afectada,
5. usar ablaciones para estimar el aporte de componentes del sistema,
6. evaluar calibración, robustez, sesgo y explicabilidad,
7. comunicar resultados sin exagerar la confiabilidad del sistema.

2. Contexto académico de MCC225

MCC225 estudia modelos que integran modalidades heterogéneas mediante representaciones compartidas, alineamiento, fusión, atención cruzada, modelos fundacionales y agentes multimodales. En semanas previas, el estudiante puede haber revisado BERT, VisualBERT, UNITER, ViLT, FLAVA, SimVLM, BLIP, BLIP-2, Flamingo, KOSMOS-1, LLaVA y otros MLLMs. Esos modelos explican cómo se conectan visión y lenguaje. Esta lectura pregunta algo diferente: **cómo se comprueba que esa conexión funciona y bajo qué condiciones falla.**

En multimodalidad, la evaluación es más difícil que en tareas puramente textuales. La entrada puede incluir imágenes con texto visible, preguntas en lenguaje natural, diagramas, tablas, audio, video o documentos. La salida puede ser una etiqueta, una respuesta corta, un caption, una explicación, una acción de agente o una generación abierta. Por ello, un único número agregado suele ocultar fallas importantes.

Un trabajo de posgrado en MCC225 debe evitar dos extremos: por un lado, una demo con ejemplos exitosos; por otro, una tabla de métricas sin interpretación. La evaluación responsable exige ambas cosas: medición cuantitativa y auditoría cualitativa.

3. Problema central de la evaluación multimodal

3.1. Más allá de una métrica única

Un sistema multimodal puede obtener buen promedio y fallar en capacidades críticas. Un modelo de VQA puede acertar preguntas simples, pero fallar en OCR o conteo. Un modelo de captioning puede producir texto fluido, pero mencionar objetos que no existen. Un sistema de recuperación imagen-texto puede tener buen Recall@10, pero confundir relaciones espaciales. Un agente multimodal puede responder bien en modo conversacional, pero seguir una instrucción maliciosa oculta en una imagen.

La evaluación debe capturar simultáneamente:

- capacidad perceptual,
- alineamiento entre modalidades,
- grounding visual o documental,
- razonamiento composicional,
- robustez ante cambios de prompt o entrada,
- sesgo de datos, idioma, cultura o dominio,

- calibración de la confianza,
- seguridad frente a inyección multimodal,
- costo computacional y reproducibilidad,
- severidad de errores.

3.2. Benchmarks frente a evaluación propia

Los benchmarks permiten comparar modelos bajo protocolos comunes. Sin embargo, no sustituyen la evaluación propia del proyecto. Un benchmark puede medir una capacidad general, pero el proyecto de un estudiante puede estar centrado en documentos académicos, imágenes educativas, diagramas, datos en español, RAG multimodal o agentes con herramientas. Por ello, la evaluación final debe combinar referencias estandarizadas y evidencia contextual del proyecto.

4. Taxonomía mínima de tareas multimodales

Antes de escoger métricas, se debe identificar el contrato de la tarea. La Tabla 1 resume una taxonomía operativa para MCC225.

Tabla 1: Tareas multimodales y métricas iniciales para MCC225.

Tarea	Pregunta experimental	Métricas posibles
Captioning	El texto generado describe correctamente la imagen sin inventar objetos relevantes.	BLEU, METEOR, ROUGE, CIDEr, SPICE, CLIPScore, evaluación humana.
Recuperación imagen-texto	El sistema recupera el texto correcto dada una imagen o la imagen correcta dado un texto.	Recall@K, MRR, mediana de ranking, mean rank.
VQA	El sistema responde una pregunta visual de forma correcta y grounded.	Accuracy, VQA score, exact match normalizado, accuracy por categoría.
Clasificación multimodal	La combinación de modalidades mejora la decisión frente a una sola modalidad.	Accuracy, macro-F1, matriz de confusión, ECE, Brier score.
Grounding	La respuesta se apoya en regiones, objetos o evidencias correctas.	IoU, pointing game, precisión de localización, inspección cualitativa.
Razonamiento visual	La solución exige contar, comparar, leer texto, ubicar objetos o combinar evidencias.	Accuracy por habilidad, Winoground score, análisis de errores.
RAG multimodal	La respuesta usa documentos, imágenes, OCR o fragmentos recuperados como evidencia.	Recall de recuperación, grounded answer rate, faithfulness, error de cita.
Agente multimodal	El sistema observa, recupera, usa herramientas, recuerda y actúa.	Tasa de éxito, tool error rate, abstention rate, seguridad y trazas auditables.

La regla metodológica es simple: **la métrica debe corresponder al contrato de la tarea**. Si el sistema promete recuperar imágenes, se evalúa ranking. Si promete responder preguntas visuales, se evalúa exactitud y razonamiento por categoría. Si promete explicar, se evalúa evidencia, trazabilidad y errores de grounding.

5. Métricas para sistemas multimodales

5.1. Métricas automáticas

Las métricas automáticas son necesarias para comparar configuraciones y repetir experimentos. Sin embargo, no deben interpretarse sin contexto. En captioning, BLEU y ROUGE capturan coincidencia superficial con referencias; METEOR, CIDEr y SPICE aproximan mejor contenido semántico, aunque siguen dependiendo de referencias. En recuperación, Recall@K y MRR miden ranking. En VQA, accuracy y VQA score dependen de normalización y de la formulación de la respuesta. En alineamiento global, CLIPScore puede ser útil, pero no demuestra por sí solo razonamiento espacial ni conteo.

5.2. Métricas humanas y rúbricas

Las salidas abiertas requieren inspección humana o rúbricas. Una rúbrica mínima para MCC225 puede usar cuatro dimensiones:

1. **Corrección:** la respuesta coincide con la evidencia disponible.
2. **Compleitud:** cubre lo necesario sin omisiones graves.
3. **Grounding:** se apoya en imagen, OCR, audio, video o documento recuperado.
4. **Seguridad:** evita afirmaciones no justificadas, sesgos o recomendaciones fuera de alcance.

5.3. LLM-as-a-judge

Un juez LLM puede acelerar evaluaciones abiertas, pero introduce incertidumbre. Debe reportarse el prompt del juez, el modelo usado, la temperatura, ejemplos auditados manualmente y casos de desacuerdo. En posgrado, un juez automático no reemplaza el análisis de error; lo complementa.

6. Winoground y razonamiento composicional

6.1. Qué mide Winoground

Winoground evalúa si un modelo visión-lenguaje distingue composición fina entre dos imágenes y dos captions. La dificultad no está en reconocer palabras u objetos aislados, sino en asociar roles, atributos, acciones y relaciones con la imagen correcta. Un caso conceptual es:

Listing 1: Ejemplo conceptual tipo Winoground.

Imagen A: un perro sigue a una persona Imagen B: una persona sigue a un perro Caption A: un perro sigue a una persona Caption B: una persona sigue a un perro

Un modelo que solo use bolsa de palabras puede detectar “perro”, “persona” y “sigue”, pero fallar en quién realiza la acción. Por eso Winoground es valioso para MCC225: revela errores que una similitud global puede ocultar.

6.2. Scores básicos

Sea S una matriz de similitud 2×2 , donde s_{ij} compara la imagen i con el caption j :

$$S = \begin{bmatrix} s_{00} & s_{01} \\ s_{10} & s_{11} \end{bmatrix}.$$

El score de imagen exige que cada imagen prefiera su caption correcto:

$$\text{image score} = \mathbb{I}(s_{00} > s_{01} \wedge s_{11} > s_{10}).$$

El score de texto exige que cada caption prefiera su imagen correcta:

$$\text{text score} = \mathbb{I}(s_{00} > s_{10} \wedge s_{11} > s_{01}).$$

El group score exige ambas condiciones:

$$\text{group score} = \text{image score} \cdot \text{text score}.$$

6.3. Uso recomendado en MCC225

Winoground debe usarse como inspiración metodológica incluso si el estudiante no ejecuta el benchmark completo. Un proyecto puede construir 30 a 100 pares controlados con inversión de roles, relaciones espaciales, atributos cruzados, conteo y ambigüedad. El informe debe mostrar matriz de similitud, score, casos fallidos y explicación del fenómeno evaluado.

7. Reproducibilidad experimental

7.1. Reproducibilidad como parte de la evaluación

Una evaluación no es reproducible solo porque el código se pueda ejecutar. Debe existir trazabilidad suficiente para reconstruir el experimento: datos, prompts, preprocesamiento, versiones de modelos, librerías, hardware, semillas, número de muestras, costo, métricas, post-procesamiento y salidas crudas.

7.2. Configuración mínima

Listing 2: Archivo mínimo de configuración para una evaluación multimodal.

```
experiment:
  name: mcc225_eval_multimodal
  seed: 123
  task: visual_question_answering
  model: modelo_vlm_base
  model_version: checkpoint_o_commit
  dataset: subconjunto_mcc225
  split: test
  num_samples: 100
  prompt_template: prompts/vqa_es.txt
  metrics:
    - accuracy
    - accuracy_by_category
    - hallucination_rate
    - ece
  outputs:
    raw_predictions: results/predictions.jsonl
    summary: results/summary.json
    error_matrix: results/errors.csv
runtime:
  python: 3.11
  device: cuda
  batch_size: 8
```

7.3. Checklist de trazabilidad

Tabla 2: Checklist mínimo de reproducibilidad para MCC225.

Elemento	Debe reportarse
Modelo	Nombre, versión, checkpoint, parámetros de inferencia.
Datos	Fuente, partición, número de muestras, criterios de filtrado.
Prompts	Plantillas completas, idioma, instrucciones del sistema si existen.
Preprocesamiento	Resolución, OCR, tokenización, truncamiento, normalización.
Métricas	Definición operativa, script usado, post-procesamiento.
Hardware	CPU, GPU, memoria, entorno local o remoto.
Software	Python, librerías, commit del repositorio, versión del tool-kit.
Aleatoriedad	Semillas, muestreo, temperatura, top-p, beam search si aplica.
Salidas	Predicciones crudas, resultados agregados, logs y matriz de errores.
Limitaciones	Alcance, sesgos, amenazas a la validez y costo.

8. Análisis de error

8.1. Por qué el análisis de error es obligatorio

El promedio no explica el comportamiento del sistema. El análisis de error permite identificar patrones: fallas de OCR, alucinaciones, sesgos culturales, dependencia del prompt, errores de localización, confusiones semánticas, memoria contaminada o uso incorrecto de herramientas. En MCC225, una evaluación sin análisis de error debe considerarse incompleta.

8.2. Matriz de errores

Tabla 3: Categorías sugeridas para la matriz de errores.

Categoría	Descripción	Evidencia esperada
Error perceptual	El modelo no reconoce un objeto, atributo, acción o relación visible.	Imagen, pregunta, respuesta, región relevante.
Error de OCR	El texto visible no se lee o se interpreta mal.	Recorte o transcripción esperada.
Error espacial	Falla en posiciones, direcciones, conteo o relaciones geométricas.	Explicación de la relación correcta.
Error composicional	Confunde roles, atributos cruzados o relaciones entre entidades.	Pares contrastivos o ejemplo tipo Winoground.
Error de conocimiento	La imagen requiere conocimiento externo que el modelo no usa bien.	Fuente o razonamiento esperado.
Alucinación visual	Menciona objetos o hechos no presentes.	Lista de objetos inventados.
Error de grounding	La respuesta no se apoya en evidencia de entrada.	Contraste entre salida y entrada.

Categoría	Descripción	Evidencia esperada
Error de prompt	La respuesta cambia por sensibilidad a la formulación.	Variantes de prompt y salidas.
Sesgo de datos	El error afecta sistemáticamente un grupo, idioma o dominio.	Subconjunto afectado.
Error de herramienta	El agente usa mal OCR, búsqueda, código, memoria o recuperación.	Traza de herramienta y salida intermedia.
Error de evaluación	La métrica penaliza o acepta indebidamente una respuesta.	Caso auditado manualmente.

8.3. Severidad

No todos los errores tienen el mismo impacto. Se recomienda clasificar severidad en tres niveles:

- **Baja:** afecta estilo o detalle menor sin cambiar la conclusión.
- **Media:** produce una respuesta incompleta o parcialmente incorrecta.
- **Alta:** inventa evidencia, induce decisión equivocada, viola seguridad o contradice la entrada.

9. Estudios de ablación

9.1. Idea principal

Una ablación consiste en quitar, reemplazar o degradar un componente para medir su aporte. En evaluación multimodal, la ablación permite detectar si el sistema realmente usa la modalidad visual, el OCR, la recuperación, la memoria o el prompt estructurado.

La lógica general es:

Listing 3: Lógica de una ablación.

```
sistema completo -> resultado A
sistema sin componente X -> resultado B
diferencia A - B -> aporte aproximado del componente X
```

9.2. Ablaciones recomendadas

Tabla 4: Ablaciones útiles para proyectos multimodales.

Ablación	Pregunta que responde	Riesgo detectado
Con imagen vs sin imagen	El modelo realmente usa evidencia visual.	Falso grounding.
Prompt simple vs prompt estructurado	La salida depende demasiado de instrucciones.	Fragilidad al prompt.
Con OCR vs sin OCR	El texto visible aporta o introduce ruido.	Error de OCR.
Con RAG vs sin RAG	La recuperación mejora fidelidad.	Recuperación contaminada.
Con memoria vs sin memoria	La memoria ayuda o sesga respuestas.	Memoria contaminada.
Imagen original vs degradada	El modelo resiste ruido razonable.	Baja robustez visual.

Ablación	Pregunta que responde	Riesgo detectado
Modelo completo vs baseline	El sistema supera una referencia simple.	Mejora no demostrada.

10. Calibración

10.1. Qué significa calibrar

La calibración evalúa si la confianza declarada por el modelo corresponde a su probabilidad real de acierto. No pregunta solamente si el modelo acertó, sino si sabe cuándo puede equivocarse.

Si un modelo afirma 90 % de confianza, debería acertar cerca del 90 % de las veces en ese rango. Si acierta solo 60 %, está sobreconfiado. La sobreconfianza es especialmente peligrosa en sistemas multimodales porque una respuesta fluida puede ocultar falta de evidencia visual.

10.2. ECE y Brier score

Una métrica común es el error esperado de calibración:

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|,$$

donde B_m es un grupo de ejemplos con confianza similar, $\text{acc}(B_m)$ es la exactitud en ese grupo y $\text{conf}(B_m)$ es la confianza promedio.

El Brier score penaliza probabilidades mal asignadas:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2.$$

10.3. Uso práctico en MCC225

Una versión mínima consiste en registrar predicción, confianza, acierto y categoría. Luego se agrupan los ejemplos por confianza baja, media y alta. El informe debe identificar casos de alta confianza incorrecta, porque esos casos son más riesgosos que errores reconocidos como inciertos.

11. Robustez y pruebas de confiabilidad

11.1. Robustez

La robustez mide estabilidad ante perturbaciones razonables. En multimodalidad, esas perturbaciones pueden afectar el texto, la imagen, el OCR, el orden de ejemplos, el prompt, la resolución, el recorte, la compresión o el dominio.

11.2. Pruebas mínimas

1. Cambiar el prompt manteniendo el mismo significado.
2. Reducir resolución o agregar ruido moderado a la imagen.
3. Usar una imagen con varios objetos o texto visible.
4. Cambiar el orden de ejemplos en un prompt few-shot.
5. Comparar contra una configuración sin OCR o sin recuperación.

Un sistema puede clasificarse como confiable solo en condiciones controladas, parcialmente

confiable o no confiable para uso real. Esa clasificación debe justificarse con evidencia, no con intuición.

12. Confiabilidad, sesgo y uso responsable

12.1. Confiabilidad

Un sistema multimodal confiable debe comportarse de forma estable dentro de su alcance, reconocer incertidumbre, evitar alucinaciones críticas, mantener grounding y no ocultar limitaciones. La confiabilidad no se deriva automáticamente de una métrica alta. Requiere evidencia de desempeño, errores, robustez, calibración y límites.

12.2. Sesgo

El sesgo puede aparecer en la modalidad visual, lingüística, cultural o de dominio. Un modelo puede funcionar mejor con imágenes de ciertos contextos, estilos visuales, idiomas, grupos demográficos o convenciones culturales. Si la muestra es pequeña, no siempre se puede demostrar sesgo estadísticamente, pero sí se debe discutir como amenaza a la validez.

12.3. Ficha mínima de uso responsable

Tabla 5: Ficha mínima de uso responsable.

Aspecto	Debe responderse
Alcance permitido	En qué condiciones puede usarse el sistema.
Uso no recomendado	En qué escenarios sería irresponsable usarlo.
Supervisión humana	Qué decisiones requieren revisión humana.
Riesgo principal	Qué error tendría mayor impacto.
Sesgo posible	Qué grupos, dominios o idiomas podrían estar subrepresentados.
Comunicación de incertidumbre	Cómo se informa baja confianza o evidencia insuficiente.

13. Explicabilidad e interpretabilidad

13.1. Explicar no es racionalizar

Una explicación multimodal debe apoyarse en evidencia observable: región visual, objeto, relación espacial, texto OCR, audio, fragmento recuperado, tabla, documento o salida de herramienta. Una frase convincente no basta. En modelos con Chain of Thought multimodal, el racional puede ayudar a organizar la respuesta, pero no garantiza que el modelo haya razonado causalmente de esa forma.

13.2. Criterios de interpretabilidad

Para MCC225, una explicación aceptable debe:

1. indicar qué evidencia fue usada,
2. separar observación de inferencia,
3. reconocer incertidumbre si la evidencia es ambigua,
4. permitir detectar errores de grounding,
5. no inventar causas no verificables.

14. Agentes multimodales y seguridad

14.1. Arquitectura agentic

Un agente multimodal puede combinar un MLLM con herramientas, memoria, recuperación, OCR, búsqueda, código, bases de datos y planificadores. La arquitectura conceptual es:

Listing 4: Arquitectura conceptual de un agente multimodal.

```

entrada multimodal
-> percepción: visión, OCR, audio, video
-> recuperación: documentos, imágenes, memoria
-> razonamiento: MLLM, planificador, verificador
-> herramientas: búsqueda, código, API, base de datos
-> salida: respuesta, acción, reporte o decisión

```

14.2. Riesgos de inyección multimodal

La inyección multimodal ocurre cuando una imagen, documento, captura, PDF, audio o texto OCR contiene instrucciones que intentan modificar el comportamiento del agente. Por ejemplo, una imagen podría incluir texto visible que diga: “ignora las instrucciones anteriores”. Si el agente trata contenido observado como instrucción válida, puede revelar información, usar herramientas indebidamente o contaminar memoria.

14.3. Controles de seguridad

Tabla 6: Controles mínimos para agentes multimodales.

Control	Propósito
Separación de roles	Distinguir instrucciones del usuario, sistema, herramienta y contenido observado.
Validación de herramientas	Restringir permisos y verificar argumentos antes de ejecutar acciones.
Trazas auditables	Guardar observaciones, prompts, herramientas llamadas y respuestas intermedias.
Verificación de evidencia	Exigir citas, regiones, OCR o documentos recuperados para afirmaciones críticas.
Abstención	Permitir “no hay evidencia suficiente” cuando la entrada es ambigua.
Memoria controlada	Evitar guardar contenido no verificado o instrucciones adversariales.
Revisión humana	Escalar decisiones sensibles a supervisión humana.

15. Comunicación responsable de resultados

15.1. Qué debe comunicarse

Un reporte responsable debe decir qué se evaluó, con qué datos, qué métrica se usó, qué fallas aparecieron, qué limitaciones existen y qué afirmaciones no están justificadas. La conclusión debe ser proporcional a la evidencia.

15.2. Frases aceptables y no aceptables

Tabla 7: Comunicación responsable frente a comunicación exagerada.

Aceptable	No aceptable
El sistema obtuvo 78 % de accuracy en 100 ejemplos controlados.	El sistema entiende imágenes en general.
El rendimiento baja en casos con OCR borroso.	El sistema es robusto.
Se observaron alucinaciones visuales en 4 de 50 casos auditados.	El sistema no alucina.
El modelo es parcialmente confiable bajo las condiciones probadas.	El modelo es confiable para uso real.
La evidencia no permite afirmar desempeño fuera del dominio evaluado.	El sistema funcionará en cualquier dominio.

16. Criterios mínimos de calidad experimental

Para MCC225, un informe aceptable debe cumplir los criterios de la Tabla 8.

Tabla 8: Criterios mínimos de calidad experimental para MCC225.

Criterio	Estándar mínimo
Pregunta experimental	Debe ser específica, evaluable y conectada al proyecto.
Tarea definida	Debe quedar claro si es captioning, retrieval, VQA, grounding, RAG o agente.
Datos documentados	Debe indicarse fuente, tamaño, partición y criterios de selección.
Métricas justificadas	Cada métrica debe relacionarse con la tarea y sus límites.
Baseline	Debe existir una referencia simple o modelo comparativo si es posible.
Ablación	Debe evaluarse al menos un componente crítico.
Calibración	Debe reportarse confianza o incertidumbre cuando sea posible.
Resultados cuantitativos	Deben presentarse tablas o agregados verificables.
Errores cualitativos	Deben analizarse aciertos, fallos y casos ambiguos.
Reproducibilidad	Deben guardarse comandos, versiones, configuración y salidas.
Limitaciones	Deben discutirse alcance, sesgo, costo y amenazas a la validez.
Responsabilidad	Deben declararse riesgos, supervisión humana y comunicación de incertidumbre.

17. Ejemplo de pipeline experimental para MCC225

17.1. Escenario

Considere un proyecto que evalúa un modelo visión-lenguaje para responder preguntas sobre material educativo con imágenes, diagramas y texto incrustado. El objetivo no es solo obtener accuracy, sino entender qué tipos de preguntas resuelve, dónde falla y si puede usarse de forma responsable.

17.2. Fases

1. Definir categorías: percepción, OCR, razonamiento espacial, conocimiento y explicación.
2. Construir un subconjunto de evaluación balanceado por categoría.
3. Ejecutar el modelo con prompts fijos y temperatura controlada.
4. Guardar predicciones crudas en JSONL.
5. Calcular métricas principales y secundarias.
6. Separar resultados por categoría.
7. Ejecutar una ablación: sin imagen, sin OCR, sin RAG o prompt alternativo.
8. Registrar confianza y calcular una medida simple de calibración.
9. Auditar manualmente errores representativos.
10. Clasificar errores por categoría, severidad y modalidad afectada.
11. Redactar limitaciones, riesgos y condiciones de uso.
12. Concluir solo dentro del alcance de la evidencia.

18. Errores conceptuales frecuentes

18.1. Confundir demo con evaluación

Mostrar cinco ejemplos exitosos no prueba desempeño. Una demo sirve para ilustrar, pero una evaluación requiere datos, procedimiento, métrica, baseline y análisis de errores.

18.2. Reportar solo el mejor resultado

Seleccionar únicamente el resultado más favorable genera una imagen incompleta. Se deben reportar configuraciones probadas, fallas y decisiones de filtrado.

18.3. Usar métricas incompatibles con la tarea

No tiene sentido evaluar una tarea de ranking solo con accuracy, ni una salida abierta solo con coincidencia exacta sin normalización o rúbrica.

18.4. Omitir el post-procesamiento

En VQA y benchmarks de opción múltiple, el post-procesamiento puede cambiar el resultado. Debe registrarse como parte del pipeline.

18.5. Ignorar alucinaciones

En sistemas multimodales, inventar objetos o relaciones puede ser más grave que omitir detalles. La fluidez lingüística no implica grounding visual.

18.6. Declarar confiabilidad sin calibración ni límites

Un resultado alto no autoriza afirmar que el sistema es confiable. La confiabilidad exige robustez, calibración, análisis de errores, límites explícitos y supervisión humana cuando corresponda.

19. Producto esperado para el estudiante

Al finalizar esta unidad, el estudiante debería entregar una lectura aplicada o mini-informe con la siguiente estructura:

1. problema y tarea multimodal,
2. modelo evaluado,
3. datos y partición,
4. métricas y justificación,
5. configuración reproducible,
6. resultados cuantitativos,
7. estudio de ablación,
8. calibración o análisis de confianza,
9. análisis de errores,
10. discusión de limitaciones,
11. riesgos, sesgo y uso responsable,
12. conclusión proporcional a la evidencia.

20. Ruta conceptual final

La progresión conceptual para MCC225 puede resumirse así:

1. Los modelos multimodales convierten modalidades heterogéneas en representaciones compatibles.
2. La atención, la fusión, el Q-Former, la proyección visual o la atención cruzada permiten conectar imagen y lenguaje.
3. Las métricas cuantitativas miden desempeño parcial, pero no explican todos los errores.
4. Winoground revela fallas de composición que el alineamiento global puede ocultar.
5. La reproducibilidad exige datos, prompts, versiones y salidas crudas.
6. La ablación muestra qué componentes aportan realmente.
7. La calibración muestra si el sistema sabe cuándo puede equivocarse.
8. La confiabilidad requiere robustez, grounding, límites y comunicación responsable.
9. Los agentes multimodales agregan herramientas y memoria, pero también nuevos riesgos de seguridad.

21. Conclusión

La evaluación de sistemas multimodales es una actividad metodológica central, no un trámite final. Un modelo puede reconocer objetos y aun así fallar en roles, relaciones espaciales, OCR, conteo, grounding o seguridad. Por eso, la calidad de un sistema no puede resumirse en un único número.

Para MCC225, la conclusión principal es que un proyecto multimodal debe evaluarse con la misma seriedad con la que se implementa. Un buen informe no solo muestra que el modelo acierta; también explica cuándo falla, por qué falla, qué tan estable es, qué tan calibrado está, qué componentes aportan, qué riesgos introduce y qué afirmaciones todavía no están justificadas.

A. Glosario breve

Ablación: experimento que elimina, reemplaza o degrada un componente para medir su aporte.

Alucinación visual: afirmación sobre objetos, atributos o relaciones que no están presentes en la entrada visual.

Brier score: métrica que penaliza probabilidades mal calibradas.

Calibración: relación entre confianza declarada y probabilidad real de acierto.

Contaminación de benchmark: posibilidad de que ejemplos de evaluación o datos similares hayan aparecido durante entrenamiento o ajuste.

ECE: Expected Calibration Error, métrica que compara confianza promedio y exactitud por grupos de confianza.

Grounding: vínculo verificable entre una salida del modelo y evidencia presente en las modalidades de entrada.

Inyección multimodal: intento de insertar instrucciones maliciosas dentro de imágenes, OCR, audio, documentos o contenido recuperado.

LLM-as-a-judge: uso de un modelo de lenguaje para puntuar o comparar respuestas generadas por otro sistema.

MRR: mean reciprocal rank, métrica de ranking que recompensa ubicar la respuesta correcta en posiciones altas.

Recall@K: proporción de consultas donde el elemento correcto aparece entre los primeros K resultados.

Reproducibilidad: capacidad de reconstruir una evaluación a partir de código, datos, configuración, versiones y salidas documentadas.

Robustez: estabilidad del comportamiento ante perturbaciones razonables de entrada, prompt, formato o dominio.

Winoground: benchmark de composición visión-lenguaje basado en dos imágenes y dos captions contrastivos.

Referencias

- [1] Thrush, T., Jiang, R., Bartolo, M., Singh, A., Williams, A., Kiela, D., y Ross, C. *Winoground: Probing Vision and Language Models for Visio-Linguistic Compositionality*. CVPR, 2022. <https://arxiv.org/abs/2204.03162>
- [2] Diwan, A., Berry, L., Choi, E., Harwath, D., y Mahowald, K. *Why is Winoground Hard? Investigating Failures in Visio-Linguistic Compositionality*. EMNLP, 2022. <https://arxiv.org/abs/2211.00768>
- [3] Li, Y., Du, Y., Zhou, K., Wang, J., Zhao, W. X., y Wen, J.-R. *Evaluating Object Hallucination in Large Vision-Language Models*. arXiv:2305.10355, 2023. <https://arxiv.org/abs/2305.10355>
- [4] Fu, C., Chen, P., Shen, Y., Qin, Y., Zhang, M., Lin, X., Yang, J., Zheng, X., Li, K., Sun, X., Wu, Y., y Ji, R. *MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models*. arXiv:2306.13394, 2023. <https://arxiv.org/abs/2306.13394>
- [5] Liu, Y., Duan, H., Zhang, Y., Li, B., Zhang, S., Zhao, W., Yuan, Y., Wang, J., He, C., Liu, Z., Chen, K., y Lin, D. *MMBench: Is Your Multi-modal Model an All-around Player?* arXiv:2307.06281, 2023. <https://arxiv.org/abs/2307.06281>
- [6] Yu, W., Yang, Z., Li, L., Wang, J., Lin, K., Liu, Z., Wang, X., y Wang, L. *MM-Vet: Evaluating Large Multimodal Models for Integrated Capabilities*. arXiv:2308.02490, 2023. <https://arxiv.org/abs/2308.02490>
- [7] Duan, H., Yang, J., Qiao, Y., Fang, X., Chen, L., Liu, Y., Agarwal, A., Chen, Z., Li, M., Ma, Y., Sun, H., Zhao, X., Cui, J., Dong, X., Zang, Y., Zhang, P., Wang, J., y Chen, K. *VLMEvalKit: An Open-Source Toolkit for Evaluating Large Multi-Modality Models*. arXiv:2407.11691, 2024. <https://arxiv.org/abs/2407.11691>
- [8] Zhang, K., Li, B., Zhang, P., Pu, F., Cahyono, J. A., Hu, K., Liu, S., Zhang, Y., Yang, J., Li, C., y Liu, Z. *LMMs-Eval: Reality Check on the Evaluation of Large Multimodal Models*. arXiv:2407.12772, 2024. <https://arxiv.org/abs/2407.12772>
- [9] Lee, T., Tu, H., Wong, C. H., Zheng, W., Zhou, Y., Mai, Y., Roberts, J. S., Yasunaga, M., Yao, H., Xie, C., y Liang, P. *VHELM: A Holistic Evaluation of Vision Language Models*. arXiv:2410.07112, 2024. <https://arxiv.org/abs/2410.07112>
- [10] Liang, P. P., Goindani, A., Chafekar, T., Mathur, L., Yu, H., Salakhutdinov, R., y Morency, L.-P. *HEMM: Holistic Evaluation of Multimodal Foundation Models*. arXiv:2407.03418, 2024. <https://arxiv.org/abs/2407.03418>
- [11] Alayrac, J.-B., Donahue, J., Luc, P., et al. *Flamingo: a Visual Language Model for Few-Shot Learning*. NeurIPS, 2022. <https://arxiv.org/abs/2204.14198>
- [12] Huang, S., Dong, L., Wang, W., et al. *Language Is Not All You Need: Aligning Perception with Language Models*. arXiv:2302.14045, 2023. <https://arxiv.org/abs/2302.14045>