

Alineamiento Audio-Texto y Video-Texto

Representación Temporal, Sincronía y Problemas Específicos de Alineamiento

Material de lectura para el curso MCC225

IA Generativa y Aprendizaje Multimodal

Índice

1. Propósito del documento	4
2. Contexto académico de MCC225	4
3. Problema central del alineamiento temporal	5
3.1. Tres propiedades que deben separarse	5
3.2. Formulación general	5
3.3. La unidad de tiempo forma parte del contrato	6
4. Representación temporal	6
4.1. De la señal continua a la secuencia discreta	6
4.2. Muestreo y aliasing temporal	6
4.3. Representación temporal del audio	7
4.4. Representación temporal del video	7
4.5. Posición absoluta, relativa y tiempo físico	8
4.6. Agregación global y pérdida de orden	9
4.7. Atención condicionada por la consulta	9
5. Alineamiento audio-texto	10
5.1. Objetivo y niveles de granularidad	10
5.2. Conjunto controlado del Cuaderno 25	10
5.3. Pérdida contrastiva bidireccional	11
5.4. Recuperación exacta y confusión semántica	11
5.5. Negativos aleatorios, semánticos y temporales	12
5.6. Problemas acústicos específicos	12
5.7. Alineamiento palabra-audio y monotonicidad	12
6. Alineamiento video-texto	13
6.1. Del reconocimiento de objetos al reconocimiento de eventos	13
6.2. Frame encoder más agregación temporal	13
6.3. Convoluciones 3D y sesgo local	13
6.4. Transformers de video y costo	13
6.5. Consulta textual y localización de momentos	14
6.6. Acciones reversibles y sensibilidad al orden	15
6.7. Sesgos de dataset y atajos visuales	15
7. Sincronía audiovisual	16
7.1. Correspondencia alta con desfase	16
7.2. Desfase constante y correlación cruzada	16
7.3. Cambio de velocidad y Dynamic Time Warping	17
7.4. Drift, tasa variable y timestamps	18

7.5. Sincronía semántica frente a sincronía física	18
8. Grounding temporal	19
8.1. Intervalos y convención de límites	19
8.2. Intersección sobre unión temporal	19
8.3. Umbrales de tIoU y curvas de desempeño	19
8.4. Anotaciones múltiples e incertidumbre	20
8.5. Respuesta correcta con grounding incorrecto	20
9. Problemas específicos de alineamiento	20
9.1. Desajuste de granularidad	20
9.2. Eventos repetidos e identificabilidad	20
9.3. Solapamiento y simultaneidad	20
9.4. Relaciones temporales compuestas	21
9.5. Atajos por contexto	21
9.6. Desincronización intencional	21
9.7. Modalidad faltante o degradada	21
9.8. Negativos demasiado fáciles	21
9.9. Contaminación entre particiones	21
9.10. Evaluación sensible a duración	22
10. Evaluación experimental	22
10.1. Métricas de recuperación	22
10.2. Métricas de sincronía	22
10.3. Métricas de grounding	22
10.4. Métricas de atención	22
10.5. Bootstrap y variabilidad	22
10.6. Perturbaciones temporales obligatorias	23
10.7. Ablaciones	23
11. Integración omni, contradicción y abstención	23
11.1. Aceptar modalidades no demuestra integración	23
11.2. Detección de conflicto	23
11.3. Cobertura y exactitud selectiva	24
11.4. Modalidades faltantes	24
12. Evaluación en streaming	24
12.1. Predicción parcial	24
12.2. Latencia semántica y latencia computacional	25
12.3. Uso de evidencia futura	25
12.4. Estabilidad	26
13. Calibración e incertidumbre temporal	26

13.1. Confianza global y confianza de localización	26
13.2. Calibración por duración y modalidad	26
13.3. Abstención temporal	26
14. Protocolo reproducible para MCC225	26
14.1. Pregunta experimental	26
14.2. Configuración mínima	27
14.3. Salidas crudas	27
14.4. Múltiples semillas	27
14.5. Control de costo	28
15. Ruta de trabajo con los cuadernos 24 a 27	28
15.1. Cuaderno 24: demostrar que el video contiene tiempo	28
15.2. Cuaderno 25: comparar promedio y atención	28
15.3. Cuaderno 26: separar sincronía y grounding	28
15.4. Cuaderno 27: evaluar integración real	28
16. Amenazas a la validez	28
16.1. Validez de construcción	28
16.2. Validez interna	29
16.3. Validez externa	29
16.4. Validez estadística	29
16.5. Ambigüedad semántica	29
17. Criterios de calidad para el informe del estudiante	29
18. Conclusiones	29
A. Glosario breve	30
B. Cuadernos fuente de MCC225	30
C. Referencias	31

1. Propósito del documento

Este documento desarrolla una lectura técnica sobre alineamiento audio-texto y video-texto para MCC225. El interés no se limita a comprobar que una descripción lingüística y un archivo multimedia comparten un tema general. El objetivo es determinar si el sistema conserva la estructura temporal, reconoce la evidencia relevante, distingue instancias semánticamente próximas, estima desfases, localiza intervalos y responde de forma estable cuando la información llega progresivamente.

La exposición profundiza el trabajo realizado en los cuadernos 24, 25, 26 y 27 de la Semana 12. El Cuaderno 24 introduce la representación espacio-temporal del video y analiza muestreo, aliasing, convoluciones 3D, tubelets y sensibilidad al orden. El Cuaderno 25 estudia alineamiento contrastivo audio-texto y video-texto mediante embeddings sintéticos, pooling temporal, atención condicionada por consulta, temperatura y negativos difíciles. El Cuaderno 26 separa correspondencia semántica, sincronía audiovisual y grounding temporal, e implementa correlación cruzada, Dynamic Time Warping y localización por ventanas. El Cuaderno 27 extiende la evaluación hacia sistemas omni mediante ablaciones, modalidades faltantes, contradicciones, abstención, grounding y streaming.

La pregunta transversal es la siguiente:

¿Qué evidencia matemática y experimental permite afirmar que un sistema no solo relaciona texto, audio y video, sino que también conserva el tiempo, localiza el evento correcto y sincroniza las modalidades?

Al finalizar la lectura, el estudiante debe poder explicar por qué la similitud semántica global no equivale a alineamiento temporal, diseñar representaciones sensibles al orden, elegir métricas coherentes con la tarea y construir un protocolo reproducible que revele fallas ocultas por los promedios agregados.

2. Contexto académico de MCC225

MCC225 estudia modelos capaces de conectar modalidades heterogéneas mediante espacios latentes compartidos, atención cruzada, fusión, aprendizaje contrastivo y modelos fundacionales. En visión-lenguaje, CLIP popularizó el aprendizaje de representaciones compatibles a partir de pares imagen-texto. En audio-lenguaje, CLAP trasladó una idea contrastiva semejante a descripciones y eventos acústicos. Para video, trabajos como VATT, VideoCLIP, Frozen in Time y MERLOT Reserve incorporaron relaciones entre imagen en movimiento, sonido y lenguaje.

La incorporación del tiempo cambia el problema. Una imagen puede representarse como una configuración espacial observada en un instante, mientras que el audio y el video son señales extendidas. En ellas importan el orden, la duración, la velocidad, la simultaneidad, la repetición y la dependencia entre eventos. Una frase como “una persona deja el vaso sobre la mesa” no se identifica únicamente por la presencia de una persona, un vaso y una mesa. La interpretación depende de una transición: el vaso pasa de estar sostenido a quedar apoyado. Invertir la secuencia puede convertir la acción en “recoger el vaso”.

Por esta razón, un encoder aplicado de forma independiente a cada frame no constituye todavía un modelo temporal. La arquitectura necesita un mecanismo que conecte los instantes y la evaluación debe demostrar que ese mecanismo se utiliza. De manera análoga, representar un audio por una sola media global puede conservar el timbre o la categoría general, pero perder el instante en que se pronuncia una palabra o aparece una alarma.

El curso aborda esta dificultad desde dos niveles. El primero es representacional: cómo se transforma una señal en tokens y cómo se conserva el tiempo. El segundo es experimental: qué perturbaciones y métricas permiten comprobar que el sistema usa la evidencia temporal correcta.

3. Problema central del alineamiento temporal

3.1. Tres propiedades que deben separarse

En sistemas multimodales temporales suelen confundirse tres propiedades diferentes.

La primera es la **correspondencia semántica**. Dos modalidades presentan correspondencia cuando describen el mismo tipo de contenido. Un video de una puerta cerrándose y un audio de un golpe de puerta pueden ser semánticamente compatibles incluso cuando el sonido fue desplazado varios segundos.

La segunda es la **sincronía**. Dos modalidades están sincronizadas cuando la evidencia correspondiente ocurre en tiempos compatibles. La sincronía puede exigir precisión de milisegundos en lectura labial o tolerar segundos en recuperación de escenas extensas.

La tercera es el **grounding temporal**. Una consulta está temporalmente grounded cuando el sistema identifica el intervalo que contiene la evidencia relevante. Un modelo puede responder correctamente que aparece un aplauso, pero señalar el tramo equivocado del video.

Estas propiedades no se implican entre sí. La correspondencia puede ser alta con desfase. La sincronía puede ser correcta para un evento recurrente sin identificar cuál ocurrencia responde a la consulta. La respuesta final puede ser correcta por contexto general mientras el grounding es incorrecto.

3.2. Formulación general

Considérese una consulta textual representada por un vector normalizado

$$q \in \mathbb{R}^D,$$

y una secuencia multimodal

$$H = (h_1, h_2, \dots, h_T), \quad h_t \in \mathbb{R}^D.$$

En audio, cada h_t puede representar una ventana del espectrograma o una salida del encoder acústico. En video, puede representar un frame, un parche, un tubelet o un token producido por un encoder espacio-temporal. El alineamiento global busca una función de agregación g tal que

$$z = g(H) \in \mathbb{R}^D$$

sea comparable con q . La similitud habitual es coseno:

$$\text{sim}_{\cos}(q, z) = \frac{q^\top z}{\|q\|_2 \|z\|_2}.$$

Sin embargo, esta formulación no especifica qué instante explica la similitud. Para grounding se requiere además una distribución temporal o un intervalo:

$$\alpha = (\alpha_1, \dots, \alpha_T), \quad \hat{I} = [\hat{t}_s, \hat{t}_e].$$

Para sincronía entre audio y video se introducen dos secuencias, $A = (a_t)$ y $V = (v_t)$, y se estima una transformación temporal ϕ que relaciona sus índices. En el caso más simple,

$$\phi(t) = t + \delta,$$

donde δ es un desfase constante. Bajo cambios de velocidad, ϕ deja de ser lineal y se necesita una trayectoria de alineamiento más flexible.

3.3. La unidad de tiempo forma parte del contrato

Una predicción de desfase expresada en índices solo es interpretable si se conoce la duración de cada índice. Si el video se procesa a 25 frames por segundo, un error de dos frames equivale a 80 milisegundos. Si los tokens corresponden a tubelets de ocho frames, el mismo error nominal representa 640 milisegundos. En audio, el hop length del espectrograma o la tasa de salida del encoder cumple una función equivalente.

Por tanto, todo protocolo debe documentar el reloj físico de cada modalidad: frecuencia de audio, frames por segundo, tamaño de ventana, salto, longitud de tubelet, redondeos, recortes y conversiones entre timestamps e índices.

4. Representación temporal

4.1. De la señal continua a la secuencia discreta

Una señal de audio puede modelarse como $x(t)$ y un video como $\mathcal{V}(x, y, t)$. Los modelos no reciben esas funciones continuas. Reciben muestras:

$$x[n] = x(n\Delta_a),$$

$$V[n, h, w, c] = \mathcal{V}(h\Delta_x, w\Delta_y, n\Delta_v, c).$$

Los intervalos Δ_a y Δ_v pueden diferir por varios órdenes de magnitud. El audio se captura con miles de muestras por segundo, mientras que el video suele contener decenas de frames. Aun después del preprocesamiento, los tokens acústicos y visuales rara vez comparten una cuadrícula temporal exacta.

La sincronización exige, por ello, distinguir entre tiempo físico y posición en la secuencia. Dos tokens con el mismo índice no necesariamente representan el mismo instante. El token de audio puede resumir una ventana centrada en 80 ms y el token de video un frame cuya exposición comienza en 100 ms. Si se omiten los timestamps, el modelo aprende una aproximación dependiente del preprocesamiento.

4.2. Muestreo y aliasing temporal

La tasa de muestreo no es una decisión puramente computacional. Define qué fenómenos pueden observarse. Para una componente periódica de frecuencia máxima $f_{\text{máx}}$, la condición clásica de Nyquist exige

$$f_s > 2f_{\text{máx}}.$$

El movimiento real no es una senoide estacionaria, pero la intuición sigue siendo válida. Si se reduce demasiado la tasa de frames, pueden desaparecer contactos breves, cambiar la frecuencia aparente o invertirse la dirección observada. El Cuaderno 24 simula una trayectoria de 6 Hz y estima su frecuencia después de muestrearla a distintas tasas.




Figura 1: Ejemplo reproducido a partir del experimento de aliasing del Cuaderno 24. Cuando la tasa de muestreo se aproxima o cae por debajo de $2f$, la frecuencia observada deja de representar fielmente el fenómeno.

En alineamiento, este fenómeno tiene dos consecuencias. Primero, un evento puede desaparecer antes de que el modelo lo procese. Segundo, el mismo archivo evaluado con otra tasa de muestreo puede convertirse en una entrada distinta desde el punto de vista informacional. Por ello, reportar únicamente la duración del video es insuficiente; también deben reportarse los frames efectivamente procesados y la estrategia de selección.

4.3. Representación temporal del audio

El audio crudo puede dividirse en ventanas superpuestas. Tras una transformada tiempo-frecuencia, cada segmento produce un vector de energía por banda. Un encoder acústico transforma la secuencia en

$$A \in \mathbb{R}^{T_a \times D_a}.$$

El significado de T_a depende del preprocesamiento. Una ventana larga mejora la resolución en frecuencia, pero reduce la precisión temporal. Una ventana corta mejora la localización de ataques y transiciones, pero dispersa la información espectral. Esta tensión se traslada a tareas audio-texto: reconocer la categoría “música” requiere contexto largo, mientras que localizar un chasquido exige alta resolución.

Los encoders modernos reducen la secuencia mediante convoluciones, pooling o subsampling. Si el factor total es r , un token representa aproximadamente r posiciones de la entrada. La reducción abarata la atención, pero establece un límite inferior para la precisión del grounding.

4.4. Representación temporal del video

Un video discreto se expresa como

$$V \in \mathbb{R}^{T \times H \times W \times C}.$$

Procesar cada frame con un encoder 2D produce una secuencia de embeddings. Sin embargo, la agregación posterior determina si el sistema conserva el orden. Un promedio de frames es invariante ante permutación y, por tanto, no puede distinguir una secuencia de su versión barajada.

Una primera ruta arquitectónica consiste en inflar kernels 2D hacia kernels 3D. Si un kernel espacial K se replica a lo largo de τ instantes y se normaliza,

$$K_r^{(3D)} = \frac{1}{\tau} K,$$

la respuesta inicial puede preservarse sobre videos estáticos. Esta propiedad facilita reutilizar filtros espaciales, pero no garantiza sensibilidad a la dirección. Si todos los slices temporales son iguales, el kernel agrega evidencia sin codificar una orientación temporal específica.

Una segunda ruta consiste en tokenizar mediante **tubelets**. Un tubelet cubre

$$\tau \times P \times P \times C$$

y la cantidad de tokens es

$$N_V = \frac{T}{\tau} \frac{H}{P} \frac{W}{P}.$$

Aumentar P reduce resolución espacial; aumentar τ reduce resolución temporal. El Cuaderno 24 implementa esta transformación mediante `tubeletify_video`.

Listing 1: Tokenización espacio-temporal mediante tubelets, adaptada del Cuaderno 24.

```
def tubeletify_video(video, tubelet_size, patch_size):
    array = np.asarray(video)
    frames, height, width, channels = array.shape

    if frames % tubelet_size != 0:
        raise ValueError("frames no divisibles por tubelet_size")
    if height % patch_size != 0 or width % patch_size != 0:
        raise ValueError("resolución no divisible por patch_size")

    tubelets = array.reshape(
        frames // tubelet_size,
        tubelet_size,
        height // patch_size,
        patch_size,
        width // patch_size,
        patch_size,
        channels,
    )
    tubelets = tubelets.transpose(0, 2, 4, 1, 3, 5, 6)
    return tubelets.reshape(
        -1,
        tubelet_size * patch_size * patch_size * channels,
    )
```

La función no solo cambia la forma del tensor. Define qué eventos pueden separarse. Si una acción dura menos que τ , su señal queda mezclada con contenido anterior y posterior. En recuperación video-texto, esto puede producir una similitud semántica razonable, pero límites temporales imprecisos.

4.5. Posición absoluta, relativa y tiempo físico

Para evitar que los tokens sean tratados como un conjunto sin orden, se añaden embeddings temporales. En una tokenización factorada puede escribirse

$$z_{r,s}^{(0)} = u_{r,s} + e_s^{\text{espacio}} + e_r^{\text{tiempo}},$$

donde r identifica la posición temporal y s la posición espacial. Esta estrategia conserva orden relativo a la cuadrícula de entrada, pero no necesariamente el tiempo físico. Si dos videos se muestrean a tasas diferentes y ambos producen T tokens, el mismo índice temporal puede representar duraciones distintas.

En aplicaciones que combinan sensores o streaming, resulta preferible conservar timestamps o duraciones explícitas. Una codificación puede depender de t_r en segundos en lugar de usar solo el índice r . Esto permite representar intervalos irregulares, frames perdidos y tasa variable.

4.6. Agregación global y pérdida de orden

La función de agregación más simple es el promedio:

$$z_{\text{mean}} = \frac{1}{T} \sum_{t=1}^T h_t.$$

El promedio es compacto y estable, pero presenta dos limitaciones. La primera es la dilución: un evento breve contribuye proporcionalmente a su duración. La segunda es la invariancia ante permutación:

$$\frac{1}{T} \sum_t h_t = \frac{1}{T} \sum_t h_{\pi(t)}$$

para cualquier permutación π . Por tanto, el promedio puede reconocer qué elementos aparecen, pero no cómo se ordenan.

El Cuaderno 24 compara el promedio con representaciones conscientes de posición, momentos temporales y descriptores de movimiento. La evaluación adecuada no consiste solo en medir accuracy, sino en invertir o barajar la secuencia y observar si la representación cambia de forma coherente.

4.7. Atención condicionada por la consulta

En tareas de recuperación, no todos los segmentos son relevantes para todas las consultas. La atención condicionada utiliza el texto para asignar pesos:

$$s_t = q^\top \bar{h}_t, \quad \alpha_t = \text{softmax}\left(\frac{s_t}{\tau_a}\right),$$

$$z_q = \sum_{t=1}^T \alpha_t h_t.$$

La temperatura τ_a controla la concentración. Una temperatura pequeña produce distribuciones agudas y puede concentrarse en un único segmento ruidoso. Una temperatura grande aproxima una media y vuelve a diluir eventos breves.

Listing 2: Pooling mediante atención condicionada por texto, tomado del protocolo del Cuaderno 25.

```
def query_attention_pool(query_embedding, sequence, temperature):
    normalized_sequence = normalize_rows(sequence)
    normalized_query = normalize_vector(query_embedding)
    scores = normalized_sequence @ normalized_query
    weights = stable_softmax(scores / temperature)
```

```
pooled = weights @ sequence
return normalize_vector(pooled), weights
```




Figura 2: La consulta concentra la masa de atención en un evento breve insertado en una secuencia dominada por fondo. El diagnóstico debe verificar no solo el máximo, sino la masa total dentro del intervalo correcto.

Una mejora en recuperación no demuestra automáticamente grounding correcto. La atención puede concentrarse en un correlato espurio. Por eso, el Cuaderno 25 registra la masa de atención dentro del intervalo real y el índice del máximo, además de las métricas de ranking.

5. Alineamiento audio-texto

5.1. Objetivo y niveles de granularidad

El alineamiento audio-texto abarca tareas con escalas muy diferentes. En clasificación de eventos, una frase puede describir un clip completo. En recuperación, el texto selecciona un audio entre candidatos. En grounding, el texto localiza una palabra, un evento o una fuente dentro de una grabación extensa. En transcripción, el alineamiento puede requerir correspondencia entre tokens lingüísticos y regiones acústicas.

La granularidad del texto también varía. Una etiqueta como “perro” tolera una representación global. Una consulta como “dos ladridos cortos después del silbido” exige orden, conteo y relaciones temporales. Evaluar ambas con una sola métrica oculta la diferencia de dificultad.

5.2. Conjunto controlado del Cuaderno 25

El Cuaderno 25 genera ejemplos sintéticos con un vector latente individual. El texto contiene una versión perturbada de ese vector. Las secuencias de audio y video contienen el mismo vector solo dentro de un intervalo conocido; el resto es fondo y ruido. Esta construcción permite controlar cinco propiedades: candidato correcto, clase semántica, intervalo, duración y negativos de la misma clase.

Listing 3: Generación conceptual de un ejemplo multimodal con evento localizado.

```
@dataclass
class MultimodalSample:
    sample_id: str
    class_name: str
    text_embedding: np.ndarray
    audio_sequence: np.ndarray
```

```

video_sequence: np.ndarray
event_start: int
event_end: int

# El latente individual se inserta solo en el intervalo del evento.
audio_sequence[event_start:event_end] += latent
video_sequence[event_start:event_end] += 0.85 * latent

```

La ventaja metodológica de este conjunto es que el sistema no puede justificar un fallo atribuyéndolo a anotaciones ambiguas. Se conoce exactamente dónde fue insertada la evidencia. La limitación es que los embeddings sintéticos no reproducen reverberación, fuentes superpuestas, errores fonéticos ni variación de dominio. El conjunto sirve para verificar mecanismos, no para estimar desempeño real.

5.3. Pérdida contrastiva bidireccional

Sean t_i los embeddings de texto y m_j los embeddings del medio. Para un batch de tamaño B ,

$$s_{ij} = t_i^\top m_j.$$

La pérdida texto a medio es

$$\mathcal{L}_{t \rightarrow m} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{ii}/\tau)}{\sum_{j=1}^B \exp(s_{ij}/\tau)}.$$

La dirección inversa intercambia filas y columnas, y la pérdida final suele promediar ambas direcciones:

$$\mathcal{L} = \frac{1}{2} (\mathcal{L}_{t \rightarrow m} + \mathcal{L}_{m \rightarrow t}).$$

La temperatura τ modifica la concentración de la distribución. No debe interpretarse únicamente como hiperparámetro numérico. Define cuánto penaliza el sistema las pequeñas diferencias entre el positivo y los negativos difíciles. Una temperatura baja puede amplificar ruido y falsos negativos; una temperatura alta puede impedir separar instancias próximas.

5.4. Recuperación exacta y confusión semántica

La matriz de similitud permite ordenar los candidatos. El protocolo del cuaderno calcula Recall@ K , mean reciprocal rank y nDCG. Con un único relevante por consulta,

$$\text{Recall@K} = \frac{1}{B} \sum_i \mathbb{I}\{i \in \text{TopK}(i)\},$$

mientras que

$$\text{MRR} = \frac{1}{B} \sum_i \frac{1}{\text{rank}_i}.$$

Recall@1 exige la instancia exacta en la primera posición. Recall@10 puede ser alto aun cuando el sistema confunda regularmente ejemplos de una misma clase. Por ello, el análisis debe registrar si el candidato incorrecto pertenece a la misma clase semántica. Esa información separa una falla de reconocimiento general de una confusión fina de instancia.

Listing 4: Evaluación de ranking utilizada en el Cuaderno 25.

```
def recall_at_k(ranking, k):
    hits = [
        query_index in ranking[query_index, :k]
        for query_index in range(len(ranking))
    ]
    return float(np.mean(hits))

def mean_reciprocal_rank(ranking):
    reciprocal_ranks = []
    for query_index, row in enumerate(ranking):
        position = int(np.where(row == query_index)[0][0]) + 1
        reciprocal_ranks.append(1.0 / position)
    return float(np.mean(reciprocal_ranks))
```

5.5. Negativos aleatorios, semánticos y temporales

Un negativo aleatorio suele pertenecer a otra categoría y puede ser demasiado fácil. Un negativo semántico pertenece a la misma clase, pero representa otra instancia. Un negativo temporal procede del archivo correcto, aunque se extrae de una región sin el evento.

Los negativos temporales son decisivos para distinguir archivo correcto de evidencia correcta. Si una consulta sobre una alarma asigna alta similitud a cualquier ventana del audio que contiene la alarma, el sistema ha aprendido una huella global del archivo, no un grounding local.

También aparecen falsos negativos. Dos clips diferentes pueden contener una evidencia válida para la misma descripción. La pérdida contrastiva los trata como competidores aunque ambos sean compatibles. Este problema es más grave con captions generales y batches grandes. Una solución es utilizar múltiples positivos, anotaciones de relevancia graduada o criterios que separen clase e instancia.

5.6. Problemas acústicos específicos

En datos reales, el alineamiento audio-texto enfrenta dificultades que el conjunto sintético aísla parcialmente.

Reverberación. El evento se extiende temporalmente por reflexiones y sus límites físicos dejan de ser nítidos.

Superposición. Varias fuentes pueden ocurrir simultáneamente. Una descripción puede referirse a una fuente débil mientras otra domina la energía.

Fuentes fuera de pantalla. En contenido audiovisual, el audio puede provenir de una fuente no visible. Exigir co-localización visual sería un error de evaluación.

Variación de hablante. La misma palabra cambia con acento, velocidad, edad, canal y prosodia. Un modelo puede alinear identidad acústica en lugar de contenido.

Eventos sin límites discretos. Sonidos como lluvia o tráfico tienen inicio y final graduales. La anotación por intervalo introduce incertidumbre irreducible.

Descripción incompleta. El texto puede nombrar el evento principal y omitir eventos secundarios. Penalizar toda similitud con lo omitido puede inducir interpretaciones incorrectas.

5.7. Alineamiento palabra-audio y monotonidad

Cuando el texto es una transcripción, suele esperarse un orden aproximadamente monótono: las palabras aparecen en el mismo orden que el habla. Esta estructura permite métodos como CTC o atención monótona. Sin embargo, una descripción libre no sigue necesariamente el orden

acústico. La frase “después de la música se escucha una puerta, mientras una persona habla” combina orden y simultaneidad de forma distinta al audio.

Por ello, no debe imponerse monotonía sin verificar el contrato de la tarea. La recuperación de eventos permite relaciones no monótonas; la transcripción exige una correspondencia secuencial más estricta.

6. Alineamiento video-texto

6.1. Del reconocimiento de objetos al reconocimiento de eventos

El alineamiento imagen-texto puede apoyarse en objetos y atributos visibles en un instante. El video-texto debe representar además transiciones. Una acción no es una colección de objetos, sino una trayectoria de estados.

El atajo más frecuente consiste en usar el fondo o los objetos como proxy de la acción. Un modelo puede asociar “jugar fútbol” con césped y uniformes sin representar el movimiento del balón. La evaluación debe incluir negativos que compartan escena y objetos, pero difieran en acción, roles u orden.

6.2. Frame encoder más agregación temporal

Una arquitectura modular aplica un encoder visual f a cada frame:

$$h_t = f(V_t).$$

Posteriormente agrega la secuencia con una RNN, convolución temporal, Transformer o pooling. Esta estrategia permite reutilizar modelos de imagen, pero su capacidad temporal depende por completo del agregador. Si se usa promedio, el sistema conserva apariencia media. Si se añade posición y autoatención, puede representar dependencias entre frames.

Para comprobar sensibilidad temporal, deben compararse al menos cuatro entradas: secuencia original, secuencia invertida, frames barajados y secuencia con frames eliminados. Un modelo que produce casi la misma similitud para todas ellas no está utilizando el orden de forma sustantiva.

6.3. Convoluciones 3D y sesgo local

Las convoluciones 3D conectan tiempo y espacio dentro de una vecindad local. Su sesgo inductivo favorece patrones de movimiento próximos. La profundidad amplía el campo receptivo, pero la resolución temporal se reduce con strides y pooling.

Inflar filtros 2D preserva parcialmente conocimiento espacial, aunque los filtros deben especializarse para distinguir dirección. Un filtro temporal simétrico puede detectar cambio, pero no necesariamente distinguir antes y después. Por ello, las perturbaciones de orden siguen siendo necesarias incluso si la arquitectura contiene kernels 3D.

6.4. Transformers de video y costo

Si el video produce N_V tokens, la atención completa tiene costo aproximado

$$\mathcal{O}(N_V^2 D).$$

Como N_V crece con tiempo y espacio, la atención completa puede volverse prohibitiva. Las arquitecturas factoradas separan atención espacial y temporal, utilizan ventanas, sparsity o tokenización más gruesa. Cada reducción de costo cambia la conectividad y puede dificultar eventos largos o breves.

La evaluación debe relacionar precisión con presupuesto. Un modelo puede mejorar al usar más frames, no por una representación superior, sino porque recibe más evidencia. Deben reportarse cantidad de frames, resolución, longitud de contexto y costo por ejemplo.

6.5. Consulta textual y localización de momentos

En video moment retrieval, una consulta textual busca un intervalo. Sea una secuencia de features H y una consulta q . Un baseline recorre ventanas de tamaño w y calcula

$$z_s = \frac{1}{w} \sum_{t=s}^{s+w-1} h_t, \quad r_s = \text{sim}_{\cos}(q, z_s).$$

La predicción es

$$\hat{s} = \arg \max_s r_s, \quad \hat{I} = [\hat{s}, \hat{s} + w].$$

El Cuaderno 26 implementa exactamente esta lógica. El baseline es útil porque hace explícita la relación entre consulta, ventana y resolución. Su limitación es asumir una duración fija. Si el evento real es más corto o más largo, puede localizar el centro y fallar en los límites.

Listing 5: Localización temporal por similitud de ventanas, adaptada del Cuaderno 26.

```
def localize_event(sequence, query, window_size):
    normalized_query = query / np.clip(
        np.linalg.norm(query), 1e-12, None
    )
    scores = []

    for start in range(0, len(sequence) - window_size + 1):
        window = sequence[start:start + window_size]
        window_embedding = window.mean(axis=0)
        window_embedding /= np.clip(
            np.linalg.norm(window_embedding), 1e-12, None
        )
        scores.append(float(window_embedding @ normalized_query))

    best_start = int(np.argmax(scores))
    return (best_start, best_start + window_size), np.asarray(scores)
```


7. Sincronía audiovisual

7.1. Correspondencia alta con desfase

Considérese un video de un golpe y su audio. Si el sonido se desplaza, la media global de ambas modalidades puede mantenerse. Un sistema contrastivo entrenado sobre clips completos puede declarar correspondencia correcta sin detectar la desincronización.

La sincronía debe evaluarse con perturbaciones explícitas. Se desplaza una modalidad por distintos offsets y se mide si el modelo identifica el desfase. Los negativos deben incluir el mismo contenido con desplazamientos pequeños, no solo clips diferentes.

7.2. Desfase constante y correlación cruzada

Para señales escalares a_t y v_t , la correlación cruzada evalúa

$$C(\delta) = \frac{\sum_t (a_t - \bar{a})(v_{t+\delta} - \bar{v}_\delta)}{\|a - \bar{a}\|_2 \|v_\delta - \bar{v}_\delta\|_2}.$$

El estimador es

$$\hat{\delta} = \arg \max_{\delta \in [-D, D]} C(\delta).$$

El Cuaderno 26 genera una señal suave, la desplaza y prueba offsets dentro de un rango. La implementación completa con ceros, normaliza y selecciona el máximo.

Listing 6: Estimación de desfase por correlación cruzada normalizada.

```
def normalized_cross_correlation(reference, observed, max_offset):
    offsets = np.arange(-max_offset, max_offset + 1)
    scores = []

    for offset in offsets:
        aligned = shift_sequence(observed, -int(offset))
        first = reference - reference.mean()
        second = aligned - aligned.mean()
        denominator = np.linalg.norm(first) * np.linalg.norm(second)
        score = 0.0 if denominator == 0.0 else first @ second / denominator
        scores.append(float(score))

    return offsets, np.asarray(scores)

def estimate_time_offset(reference, observed, max_offset):
    offsets, scores = normalized_cross_correlation(
        reference, observed, max_offset
    )
    best = int(np.argmax(scores))
    return int(offsets[best]), float(scores[best])
```




Figura 4: Curvas de correlación para tres desfases controlados. El máximo se desplaza con la señal observada y permite recuperar offsets constantes cuando el evento es identificable.

La correlación funciona si el desfase es constante, las señales comparten estructura y no existen múltiples repeticiones indistinguibles. También es sensible al tratamiento de bordes. Completar con ceros cambia la media y la norma; comparar solo la región solapada puede producir otra estimación. El protocolo debe documentar esta decisión.

7.3. Cambio de velocidad y Dynamic Time Warping

Un desfase único no alinea señales cuya velocidad cambia. Si el audio fue estirado, si el video perdió frames o si los relojes presentan drift, la correspondencia entre índices es no lineal.

Dynamic Time Warping construye una matriz acumulada. Para secuencias $x_1, \dots, x_n$ e $y_1, \dots, y_m$,

$$D_{i,j} = c(x_i, y_j) + \min\{D_{i-1,j}, D_{i,j-1}, D_{i-1,j-1}\}.$$

La trayectoria puede repetir una posición de una modalidad o avanzar en ambas. El Cuaderno 26 implementa la versión clásica con costo absoluto.

Listing 7: Dynamic Time Warping utilizado en el Cuaderno 26.

```
def dynamic_time_warping(first_sequence, second_sequence):
    n = len(first_sequence)
    m = len(second_sequence)
    accumulated = np.full((n + 1, m + 1), np.inf)
    accumulated[0, 0] = 0.0

    for i in range(1, n + 1):
        for j in range(1, m + 1):
            local_cost = abs(first_sequence[i - 1] - second_sequence[j - 1])
            accumulated[i, j] = local_cost + min(
                accumulated[i - 1, j],
                accumulated[i, j - 1],
                accumulated[i - 1, j - 1],
            )

    distance = accumulated[n, m] / (n + m)
    return float(distance), accumulated
```




Figura 5: Comparación entre distancia directa y DTW bajo factores de velocidad. DTW tolera deformaciones locales, aunque su flexibilidad debe restringirse para evitar alineamientos artificiales.

El costo clásico es $\mathcal{O}(nm)$ en tiempo y memoria. En secuencias largas se emplean bandas de Sakoe-Chiba, aproximaciones o features a menor tasa. La flexibilidad de DTW es simultáneamente una ventaja y un riesgo: puede alinear eventos semánticamente distintos si el costo local no es discriminativo.

7.4. Drift, tasa variable y timestamps

En grabaciones largas, la diferencia entre relojes puede crecer progresivamente. Un modelo simple es

$$t_v = \alpha t_a + \beta,$$

donde β es offset y α representa drift. Si $\alpha \neq 1$, el desfase cambia con el tiempo. La correlación local puede estimar offsets en ventanas y luego ajustar una función. DTW puede modelar deformaciones más generales, pero pierde interpretabilidad física.

Los videos con tasa variable requieren timestamps reales. Suponer $t = n/f_s$ introduce errores cuando los frames no están espaciados uniformemente. El preprocesamiento debe decidir entre remuestrear a una cuadrícula regular o conservar posiciones irregulares.

7.5. Sincronía semántica frente a sincronía física

No toda correspondencia audiovisual debe coincidir exactamente. Una narración puede describir una acción después de que ocurrió. La música puede anticipar un cambio visual. Un plano puede mostrar la reacción antes de revelar la fuente sonora. La evaluación debe definir si busca sincronía física, coherencia narrativa o correspondencia a nivel de escena.

Un benchmark de lip-sync requiere tolerancias pequeñas. Una tarea de recuperación de escenas puede considerar correctos varios segundos. Utilizar el mismo umbral para ambas tareas carece de sentido.

8. Grounding temporal

8.1. Intervalos y convención de límites

Un intervalo puede definirse como cerrado, abierto o semiabierto. En código suele utilizarse $[s, e)$, donde s está incluido y e excluido. La duración es

$$|I| = e - s.$$

Esta convención evita doble conteo entre intervalos adyacentes. El informe debe declararla, especialmente cuando convierte frames a segundos.

8.2. Intersección sobre unión temporal

Para un intervalo real I y uno predicho $\hat{I}$,

$$\text{tIoU}(I, \hat{I}) = \frac{|I \cap \hat{I}|}{|I \cup \hat{I}|}.$$

La tIoU combina localización y duración. Un intervalo demasiado largo puede cubrir el evento y aun obtener una puntuación moderada. Un intervalo muy corto dentro del evento también puede obtener un valor bajo a pesar de localizar el núcleo correcto.

Por ello, el Cuaderno 26 añade errores de inicio, final, centro y duración:

$$e_s = |\hat{s} - s|, \quad e_e = |\hat{e} - e|,$$

$$e_c = \left| \frac{\hat{s} + \hat{e}}{2} - \frac{s + e}{2} \right|, \quad e_d = |(\hat{e} - \hat{s}) - (e - s)|.$$

Estas métricas permiten distinguir desplazamiento, sobreextensión y duración incorrecta.

Listing 8: Métricas de intervalo implementadas en los cuadernos 24 y 26.

```
def temporal_iou(predicted, reference):
    ps, pe = predicted
    rs, re = reference
    intersection = max(0.0, min(pe, re) - max(ps, rs))
    union = (pe - ps) + (re - rs) - intersection
    return 0.0 if union <= 0 else intersection / union

def boundary_errors(predicted, reference):
    ps, pe = predicted
    rs, re = reference
    pc, rc = (ps + pe) / 2.0, (rs + re) / 2.0
    return {
        "error_inicio": abs(ps - rs),
        "error_final": abs(pe - re),
        "error_centro": abs(pc - rc),
        "error_duracion": abs((pe - ps) - (re - rs)),
    }
```

8.3. Umbrales de tIoU y curvas de desempeño

Reportar solo tIoU media puede ocultar la distribución. En recuperación de momentos se acostumbra medir recall bajo varios umbrales:

$$R@K, \text{tIoU} \geq \theta.$$

Un umbral bajo evalúa localización aproximada; uno alto exige límites precisos. La selección debe estar relacionada con la aplicación. En material educativo, localizar el segmento donde se explica un concepto puede tolerar algunos segundos. En inspección de eventos breves, la tolerancia debe ser menor.

8.4. Anotaciones múltiples e incertidumbre

Los límites de una acción no siempre son objetivos. Distintos anotadores pueden elegir el inicio del movimiento, el contacto o el cambio de estado. Una sola referencia transforma desacuerdo humano en error del modelo.

El protocolo puede conservar múltiples intervalos válidos y tomar la mejor coincidencia, modelar límites suaves o reportar acuerdo entre anotadores. La incertidumbre debe aparecer en la interpretación: no es razonable exigir precisión de un frame cuando los humanos difieren por varios frames.

8.5. Respuesta correcta con grounding incorrecto

El Cuaderno 27 simula intervalos desplazados mientras conserva parte de las etiquetas correctas. El objetivo es contar casos con respuesta correcta y tIoU menor que un umbral. Este análisis demuestra que exactitud y grounding son ejes independientes.

Un sistema puede acertar por contexto, por sesgo o por conocimiento previo. Sin evidencia temporal correcta, la respuesta no es verificable. En aplicaciones de auditoría o educación, esta diferencia es crítica: el usuario necesita saber qué segmento sustenta la afirmación.

9. Problemas específicos de alineamiento

9.1. Desajuste de granularidad

El texto puede describir un instante, un evento, una escena o una historia completa. El audio y el video pueden tokenizarse a otra escala. Si la consulta es más fina que la resolución de los tokens, el grounding no puede ser preciso. Si es más amplia, una ventana corta captura fragmentos parciales.

La duración de la consulta debe formar parte del dataset. Una evaluación estratificada por eventos breves, medios y largos revela si la mejora depende de condiciones favorables.

9.2. Eventos repetidos e identificabilidad

Cuando una señal contiene dos ocurrencias casi idénticas, la correlación o la atención puede producir varios máximos. La evidencia no identifica de forma única cuál corresponde a la consulta, salvo que exista contexto adicional.

En lugar de reportar solo el argmax, conviene registrar el margen entre los dos mejores máximos, la entropía de la distribución y múltiples intervalos candidatos. Una predicción única con alta confianza sería injustificada si la señal es ambigua.

9.3. Solapamiento y simultaneidad

Dos eventos pueden compartir tiempo. Una persona habla mientras suena música y otra abre una puerta. Un modelo que produce un único intervalo por consulta puede localizar cada evento, pero una representación global puede mezclar sus features.

La anotación debe permitir intervalos superpuestos y, cuando sea necesario, múltiples fuentes. Forzar una segmentación exclusiva introduce errores artificiales.

9.4. Relaciones temporales compuestas

Consultas como “antes”, “después”, “mientras”, “hasta que” o “dos veces” no se resuelven localizando una sola ventana. Requieren relaciones entre eventos:

$$I_A \prec I_B, \quad I_A \cap I_B \neq \emptyset, \quad \#\{I_A\} = 2.$$

Un protocolo avanzado debe construir pares contrastivos donde los mismos eventos aparecen con orden o conteo distinto. La similitud global puede ser alta para ambos, por lo que el fallo revela ausencia de razonamiento temporal composicional.

9.5. Atajos por contexto

En video, el fondo puede predecir la acción. En audio, el canal, la fuente o el ruido ambiental pueden identificar el archivo. En texto, ciertas palabras pueden correlacionarse con una clase. Las ablaciones deben eliminar o degradar cada modalidad para estimar el aporte real.

Una prueba útil es sustituir la región temporal del evento por fondo manteniendo el resto del archivo. Si la puntuación apenas cambia, el sistema no depende de la evidencia local.

9.6. Desincronización intencional

Narración, doblaje, edición cinematográfica y efectos anticipatorios producen desplazamientos válidos. Un detector de sincronía física podría marcar como error una decisión narrativa correcta. La etiqueta debe distinguir error de captura, edición intencional y correspondencia semántica no simultánea.

9.7. Modalidad faltante o degradada

Un sistema multimodal debe documentar qué ocurre cuando falta audio, video o texto. Sustituir una modalidad por ceros puede no equivaler a ausencia, porque la distribución cambia. Debe existir una máscara explícita o una política de fallback.

La degradación gradual también importa: compresión, ruido, baja iluminación, frames perdidos o transcripción imperfecta. La robustez debe evaluarse como curva, no solo con una condición extrema.

9.8. Negativos demasiado fáciles

Si los negativos pertenecen a categorías distintas, el modelo puede resolver la tarea con semántica gruesa. Los negativos difíciles deben compartir objetos, escena, hablante o evento, y diferir en instancia, tiempo, rol, orden o relación.

En sincronía, el negativo más informativo es el mismo par con un pequeño desfase. En grounding, es una ventana adyacente. En composición, es una secuencia con roles invertidos.

9.9. Contaminación entre particiones

Videos de una misma fuente pueden aparecer en entrenamiento y prueba con recortes distintos. El modelo memoriza apariencia, voz o fondo y la evaluación sobreestima generalización. La partición debe realizarse por video fuente, sesión, hablante o entidad, no solo por clip.

9.10. Evaluación sensible a duración

La tIoU favorece de forma distinta eventos largos y cortos. Un error de un segundo es pequeño para un evento de un minuto y devastador para uno de dos segundos. Por ello, deben reportarse errores absolutos en segundos y métricas normalizadas por duración.

10. Evaluación experimental

10.1. Métricas de recuperación

Para audio-texto y video-texto se recomienda reportar ambas direcciones: texto a medio y medio a texto. Las distribuciones pueden diferir porque una descripción puede corresponder a varios medios y un medio puede admitir múltiples descripciones.

Las métricas mínimas son Recall@1, Recall@5, Recall@10, MRR y mediana de ranking. Deben complementarse con resultados por duración, clase, dificultad del negativo y modalidad.

10.2. Métricas de sincronía

Sea δ_i el desfase real y $\hat{\delta}_i$ el estimado. El error absoluto medio es

$$\text{MAE}_\delta = \frac{1}{N} \sum_i |\hat{\delta}_i - \delta_i|.$$

La exactitud dentro de tolerancia es

$$\text{Acc}_\epsilon = \frac{1}{N} \sum_i \mathbb{I}\{|\hat{\delta}_i - \delta_i| \leq \epsilon\}.$$

Debe reportarse en unidades físicas además de tokens. También conviene medir el error por magnitud del desfase y nivel de ruido.

10.3. Métricas de grounding

La evaluación debe incluir tIoU media, mediana, recall a varios umbrales, errores de límites y desempeño por duración. Para consultas con múltiples ocurrencias, se necesita una política de matching entre predicciones y referencias.

10.4. Métricas de atención

Si el modelo produce pesos temporales, pueden calcularse:

- masa de atención dentro del intervalo correcto;
- distancia entre el máximo y el centro del evento;
- entropía de la distribución;
- margen entre primer y segundo máximo;
- estabilidad de la atención ante perturbaciones.

La atención no debe presentarse como explicación causal sin validación. Es un diagnóstico interno que puede o no reflejar la evidencia utilizada por la predicción.

10.5. Bootstrap y variabilidad

Una mejora puntual puede depender de la muestra. Los cuadernos implementan intervalos bootstrap para medias y ganancias. Se remuestran ejemplos con reemplazo y se calcula la distribución del estadístico.

Para una diferencia entre atención y promedio, el remuestreo debe ser pareado: en cada iteración se seleccionan los mismos índices para ambos métodos. Esto conserva la dependencia entre resultados y produce un intervalo más informativo.

10.6. Perturbaciones temporales obligatorias

Una evaluación de temporalidad debe incluir, como mínimo:

1. inversión de la secuencia;
2. barajado de frames o segmentos;
3. eliminación de frames;
4. variación de tasa de muestreo;
5. desplazamiento de una modalidad;
6. cambio de velocidad;
7. reemplazo del intervalo relevante por fondo;
8. repetición del evento en otro instante.

Cada perturbación responde una pregunta diferente. La inversión prueba dirección; el barajado prueba orden; el submuestreo prueba resolución; el desplazamiento prueba sincronía; la repetición prueba identificabilidad.

10.7. Ablaciones

El Cuaderno 27 evalúa solo texto, solo audio, solo video, combinaciones de dos modalidades y sistema completo. La ganancia multimodal se define como

$$G = M_{\text{completo}} - \text{máx}(M_{\text{texto}}, M_{\text{audio}}, M_{\text{video}}).$$

Una ganancia positiva sugiere complementariedad promedio, pero no demuestra que todas las modalidades se utilicen en cada caso. Se necesitan ablaciones por ejemplo y subgrupos donde cada modalidad sea necesaria.

11. Integración omni, contradicción y abstención

11.1. Aceptar modalidades no demuestra integración

Una interfaz que permite adjuntar texto, audio y video no es evidencia de integración. El sistema puede ignorar una modalidad, usarla solo en casos fáciles o combinar probabilidades sin sincronía.

El Cuaderno 27 define casos con evidencia concordante, complementaria, faltante y contradictoria. Cada variante se compara con las modalidades individuales. Esta estructura evita atribuir a la fusión una mejora que ya estaba presente en una modalidad dominante.

11.2. Detección de conflicto

Una política simple detecta conflicto cuando alguna modalidad apoya fuertemente la clase positiva y otra apoya la negativa. Si p_k son probabilidades y γ un umbral,

$$\exists k : p_k \geq \gamma \quad \text{y} \quad \exists j : p_j \leq 1 - \gamma.$$

Listing 9: Política de conflicto y abstención del Cuaderno 27.

```
def detect_probability_conflict(probabilities, threshold):
```

```

    if len(probabilities) < 2:
        return False
    has_positive = any(value >= threshold for value in probabilities)
    has_negative = any(value <= 1.0 - threshold for value in probabilities)
    return has_positive and has_negative

def predict_case(probabilities, decision_threshold,
                 conflict_threshold, abstain_on_conflict):
    conflict = detect_probability_conflict(
        probabilities, conflict_threshold
    )
    confidence = float(np.mean(probabilities))

    if abstain_on_conflict and conflict:
        return None, confidence, True, True

    prediction = int(confidence >= decision_threshold)
    return prediction, confidence, False, conflict

```

Promediar probabilidades presupone comparabilidad y calibración entre modalidades. En un sistema real, las escalas pueden diferir. La fusión debe calibrarse o aprenderse; de lo contrario, una modalidad sobreconfiada domina.

11.3. Cobertura y exactitud selectiva

Cuando existe abstención, la exactitud sobre respuestas emitidas puede aumentar simplemente porque el sistema rechaza casos difíciles. Deben reportarse simultáneamente:

$$\text{Cobertura} = \frac{\# \text{respuestas emitidas}}{N},$$

$$\text{Exactitud selectiva} = \frac{\# \text{respuestas correctas emitidas}}{\# \text{respuestas emitidas}},$$

además de exactitud global, tasa de abstención y desempeño en casos conflictivos. La política correcta depende del costo de error y del costo de no responder.

11.4. Modalidades faltantes

El sistema debe diferenciar una probabilidad ausente de una probabilidad igual a cero. En el cuaderno, `None` representa ausencia y la integración utiliza solo valores disponibles. En arquitecturas aprendidas, se necesitan máscaras y entrenamiento con modality dropout para evitar fallos fuera de distribución.

12. Evaluación en streaming

12.1. Predicción parcial

En streaming, el modelo recibe fragmentos $H_{1:t}$ y produce una trayectoria de predicciones. Evaluar solo el resultado final oculta la conducta durante la secuencia.

El Cuaderno 27 simula probabilidades acumuladas que se acercan a la clase correcta cuando comienza la evidencia. Las métricas incluyen tiempo hasta estabilidad, número de cambios, confianza final y exactitud final.

Listing 10: Métricas de estabilidad de streaming, adaptadas del Cuaderno 27.

```
def streaming_metrics(probabilities, label, stability_window):
    predictions = (probabilities >= 0.5).astype(int)
    flips = int(np.sum(predictions[1:] != predictions[:-1]))
    stable_index = len(predictions) - 1

    for start in range(len(predictions) - stability_window + 1):
        window = predictions[start:start + stability_window]
        if np.all(window == window[0]) and np.all(
            predictions[start:] == window[0]
        ):
            stable_index = start
            break

    return {
        "fragmento_estable": float(stable_index),
        "cambios_decision": float(flips),
        "confianza_final": float(probabilities[-1]),
        "exactitud_final": float(predictions[-1] == label),
    }
```




Figura 6: Trayectorias parciales en streaming. Dos sistemas con igual exactitud final pueden diferir en latencia, oscilaciones y momento de estabilización.

12.2. Latencia semántica y latencia computacional

La latencia total tiene dos componentes. La latencia semántica es el tiempo hasta que llega evidencia suficiente. La latencia computacional es el tiempo de procesamiento. Un modelo no puede predecir correctamente antes de observar la evidencia sin utilizar atajos o información futura.

El protocolo debe medir el timestamp del evento, el primer fragmento correcto, el primer fragmento estable y el tiempo de cómputo. Mezclar estas cantidades impide saber si el retraso proviene de la señal o de la implementación.

12.3. Uso de evidencia futura

Un modelo offline puede utilizar frames posteriores para interpretar un evento anterior. En streaming causal, esa evidencia no está disponible. Evaluar el mismo modelo con toda la secuencia y llamarlo streaming produce una fuga temporal.

La máscara de atención debe impedir acceso al futuro, y el benchmark debe ejecutar prefijos reales. También deben registrarse estados almacenados, tamaño de buffer y revisiones retrospectivas permitidas.

12.4. Estabilidad

El número de flips mide cambios discretos, pero no variaciones de confianza. Puede añadirse variación total:

$$TV(p) = \sum_{t=2}^T |p_t - p_{t-1}|.$$

Una trayectoria suave no es necesariamente correcta, pero una trayectoria altamente oscilante puede ser problemática para interfaces en tiempo real. En decisiones sensibles, la salida puede mostrarse solo después de cumplir un criterio de estabilidad.

13. Calibración e incertidumbre temporal

13.1. Confianza global y confianza de localización

Un sistema puede estar seguro de la clase y ser incierto sobre el intervalo. Deben separarse al menos dos confianzas: $p(y | x)$ para la respuesta y $p(I | q, x)$ para la localización.

La distribución de scores por ventana puede normalizarse para estimar incertidumbre. Una distribución con varios máximos indica ambigüedad temporal. Colapsarla a un solo intervalo sin reportar margen oculta esa incertidumbre.

13.2. Calibración por duración y modalidad

La calibración global puede ser buena y fallar en eventos breves. Los bins deben analizarse también por duración, nivel de ruido, modalidad faltante y conflicto. En audio, la confianza puede degradarse con superposición; en video, con submuestreo oclusión.

13.3. Abstención temporal

La abstención no tiene que ser binaria respecto de toda la respuesta. El sistema puede responder la categoría y abstenerse de dar límites precisos, o devolver un intervalo amplio. Esta salida parcial es más informativa que una localización falsa con alta confianza.

14. Protocolo reproducible para MCC225

14.1. Pregunta experimental

Una pregunta adecuada debe relacionar una intervención con una propiedad temporal. Ejemplos:

- ¿La atención condicionada mejora Recall@1 en eventos de tres segmentos frente al promedio global?
- ¿La correlación cruzada mantiene MAE menor que dos frames bajo ruido moderado?
- ¿DTW reduce la distancia frente al alineamiento directo cuando la velocidad cambia entre 0,65 y 1,5?
- ¿La inversión de frames reduce la similitud en consultas direccionales, pero no en consultas de escena?
- ¿La abstención mejora exactitud selectiva en casos contradictorios sin reducir cobertura?

por debajo del nivel acordado?

14.2. Configuración mínima

La configuración debe registrar semilla, duración, frecuencia de audio, FPS original y procesado, estrategia de muestreo, tamaño de parche y tubelet, dimensión de embeddings, temperatura, ventanas de grounding, rango de offsets, umbrales y hardware.

Listing 11: Configuración mínima sugerida para los experimentos de Semana 12.

```
experiment:
  course: MCC225
  week: 12
  seed: 225
  task: audio_video_text_temporal_alignment

input:
  audio_sample_rate_hz: 16000
  audio_window_ms: 25
  audio_hop_ms: 10
  video_original_fps: 30
  video_processed_fps: 8
  clip_duration_s: 12

representation:
  embedding_dimension: 256
  patch_size: 16
  tubelet_size: 2
  pooling: query_attention
  attention_temperature: 0.12

evaluation:
  recall_k: [1, 5, 10]
  tiou_thresholds: [0.3, 0.5, 0.7]
  offset_tolerances_frames: [1, 2, 4]
  perturbations:
    - reverse
    - shuffle
    - frame_drop
    - time_shift
    - speed_change

outputs:
  raw_predictions: resultados/predicciones.jsonl
  interval_predictions: resultados/intervalos.csv
  metadata: resultados/metadatos.json
```

14.3. Salidas crudas

Las métricas agregadas deben poder reconstruirse. Cada registro debería conservar identificador, consulta, candidato correcto, ranking, scores, intervalo real y predicho, offset real y estimado, duración, perturbación, modalidad disponible, confianza, abstención y tiempo de inferencia.

14.4. Múltiples semillas

Los cuadernos usan semillas explícitas para aislar experimentos. Una conclusión no debe depender de una sola generación sintética. Deben repetirse varias semillas y reportarse media, desviación e intervalo bootstrap. En modelos entrenados, también debe separarse variabilidad de

entrenamiento y de muestreo de evaluación.

14.5. Control de costo

La comparación debe usar presupuestos compatibles. Si un método procesa cuatro veces más frames, su ventaja puede provenir de más evidencia. Se recomienda reportar tokens, FLOPs aproximados, memoria, latencia y throughput.

15. Ruta de trabajo con los cuadernos 24 a 27

15.1. Cuaderno 24: demostrar que el video contiene tiempo

El primer paso es ejecutar los experimentos de tokenización, aliasing, inflación de kernels, crecimiento de tokens y sensibilidad al orden. La evidencia esperada es que el submuestreo cambia la observación, que los tubelets establecen una resolución temporal y que el promedio no distingue permutaciones.

El estudiante debe modificar tasas, tamaños de tubelet y duraciones de evento. La pregunta no es cuál configuración produce la mejor tabla, sino en qué punto desaparece una propiedad temporal.

15.2. Cuaderno 25: comparar promedio y atención

El segundo paso es generar ejemplos con eventos localizados y comparar audio global, audio atendido, video global y video atendido. Deben reportarse ranking y masa de atención en el evento.

Luego se introducen negativos semánticos y temporales. La atención debe mejorar especialmente cuando el evento es breve; si no lo hace, el análisis debe inspeccionar temperatura, nivel de ruido y separabilidad del latente.

15.3. Cuaderno 26: separar sincronía y grounding

El tercer paso es evaluar offsets constantes, ruido, cambios de velocidad y localización por ventanas. La correlación debe compararse por magnitud de desfase. DTW debe evaluarse con restricciones y distintas velocidades.

Finalmente se añaden eventos repetidos para demostrar falta de identificabilidad. El resultado correcto no es forzar un único offset, sino reconocer que la evidencia admite varios.

15.4. Cuaderno 27: evaluar integración real

El cuarto paso es ejecutar ablaciones de modalidades, introducir contradicciones, medir cobertura y analizar grounding separado de la respuesta. La ganancia multimodal debe compararse contra la mejor modalidad individual.

La última extensión es streaming. El estudiante debe medir estabilidad y prohibir evidencia futura. Dos modelos con igual exactitud final pueden tener comportamientos operativos muy diferentes.

16. Amenazas a la validez

16.1. Validez de construcción

Las métricas pueden no representar la capacidad declarada. Recall@10 no mide grounding; tIoU no mide semántica; correlación alta no implica causalidad. Cada afirmación debe estar

vinculada con una intervención o métrica apropiada.

16.2. Validez interna

Cambiar simultáneamente arquitectura, cantidad de frames y preprocesamiento impide atribuir la mejora. Las ablaciones deben modificar un factor crítico por vez y mantener el resto del protocolo.

16.3. Validez externa

Los embeddings sintéticos aíslan mecanismos, pero no reproducen complejidad real. La evidencia debe confirmarse con datos acústicos y visuales reales, dominios diversos y anotaciones independientes.

16.4. Validez estadística

Una muestra pequeña produce intervalos amplios. Elegir la mejor semilla o temperatura después de observar el test introduce optimismo. El tuning debe realizarse en validación y el test reservarse para la evaluación final.

16.5. Ambigüedad semántica

Una consulta puede admitir varios clips o intervalos. Tratar una única referencia como verdad absoluta penaliza respuestas válidas. El dataset debe documentar multiplicidad y acuerdo humano.

17. Criterios de calidad para el informe del estudiante

Un informe de MCC225 sobre alineamiento temporal debe incluir una pregunta experimental precisa, una descripción del reloj de cada modalidad, la tokenización, el método de agregación, las métricas de recuperación y localización, perturbaciones temporales, ablaciones, resultados por duración, análisis de errores, incertidumbre y limitaciones.

La conclusión debe ser proporcional a la evidencia. Es aceptable afirmar que una técnica mejora Recall@1 en eventos sintéticos breves bajo las semillas probadas. No es aceptable afirmar que el sistema comprende tiempo en general sin pruebas de inversión, cambio de velocidad, grounding y datos reales.

18. Conclusiones

El alineamiento audio-texto y video-texto es un problema temporal antes que una simple comparación de embeddings. El audio y el video son observaciones discretas de fenómenos continuos. La tasa de muestreo, la ventana acústica, el número de frames, el tamaño de tubelet y la agregación determinan qué evidencia llega al modelo.

El promedio global ofrece una baseline útil, pero diluye eventos breves y elimina el orden. La atención condicionada por texto puede concentrar la representación, aunque debe validarse con masa dentro del intervalo y negativos temporales. En video, las convoluciones 3D, los Transformers y los tubelets introducen capacidad temporal, pero no garantizan que el sistema la utilice. Las perturbaciones de orden y tasa son necesarias para demostrarlo.

La correspondencia semántica, la sincronía y el grounding son propiedades distintas. La correlación cruzada estima desfases constantes; DTW tolera cambios de velocidad; las métricas de intervalo evalúan localización. Eventos repetidos, anotaciones ambiguas y sincronía narrativa muestran que algunos casos no tienen una única solución.

En sistemas omni, la integración debe demostrarse mediante ablaciones y comparación con la mejor modalidad individual. Las contradicciones exigen políticas de conflicto, calibración y abstención. En streaming, la exactitud final debe complementarse con latencia y estabilidad.

La conclusión metodológica para MCC225 es que un sistema temporal se evalúa destruyendo o perturbando precisamente aquello que afirma representar. Si la salida permanece igual después de invertir, barajar, desplazar o submuestrear la secuencia, la evidencia de comprensión temporal es débil. Una evaluación rigurosa debe localizar, sincronizar, estratificar, reproducir y reconocer incertidumbre.

A. Glosario breve

Alineamiento contrastivo: aprendizaje o evaluación que acerca pares compatibles y separa pares incompatibles en un espacio latente.

Aliasing temporal: distorsión producida cuando la tasa de muestreo es insuficiente para representar la variación de la señal.

Atención condicionada: agregación cuyos pesos dependen de una consulta, por ejemplo un embedding textual.

Cobertura: proporción de casos en los que un sistema selectivo emite una respuesta.

Correspondencia semántica: compatibilidad de contenido entre modalidades sin exigir coincidencia temporal precisa.

Desfase: diferencia temporal entre eventos correspondientes de dos modalidades.

Dynamic Time Warping: alineamiento dinámico que permite repetir o saltar posiciones para compensar cambios de velocidad.

Grounding temporal: vínculo entre una consulta o respuesta y el intervalo que contiene su evidencia.

Identificabilidad: posibilidad de determinar una solución única a partir de la evidencia disponible.

Negativo temporal: segmento del archivo correcto que no contiene el evento consultado.

Sincronía: coincidencia temporal de eventos correspondientes entre modalidades.

tIoU: intersección sobre unión aplicada a intervalos temporales.

Tubelet: bloque espacio-temporal usado como token de video.

B. Cuadernos fuente de MCC225

Los ejemplos de código y el protocolo de esta lectura se basan en los siguientes cuadernos del repositorio del curso:

1. [Cuaderno24-MCC225: De imágenes a videos, representación espacio-temporal y modelos de video.](#)
2. [Cuaderno25-MCC225: Alineamiento contrastivo audio-texto y video-texto.](#)
3. [Cuaderno26-MCC225: Sincronía audiovisual y grounding temporal.](#)
4. [Cuaderno27-MCC225: Modelos omni y evaluación multimodal temporal.](#)

C. Referencias

Referencias

- [1] A. Radford et al., “Learning Transferable Visual Models From Natural Language Supervision,” en *Proceedings of ICML*, 2021.
- [2] B. Elizalde, S. Deshmukh, M. Al Ismail y H. Wang, “CLAP: Learning Audio Concepts From Natural Language Supervision,” en *Proceedings of ICASSP*, 2023.
- [3] H. Akbari et al., “VATT: Transformers for Multimodal Self-Supervised Learning from Raw Video, Audio and Text,” en *Advances in Neural Information Processing Systems*, 2021.
- [4] H. Xu et al., “VideoCLIP: Contrastive Pre-training for Zero-shot Video-Text Understanding,” en *Proceedings of EMNLP*, 2021.
- [5] M. Bain, A. Nagrani, G. Varol y A. Zisserman, “Frozen in Time: A Joint Video and Image Encoder for End-to-End Retrieval,” en *Proceedings of ICCV*, 2021.
- [6] R. Zellers et al., “MERLOT Reserve: Neural Script Knowledge through Vision and Language and Sound,” en *Proceedings of CVPR*, 2022.
- [7] G. Bertasius, H. Wang y L. Torresani, “Is Space-Time Attention All You Need for Video Understanding?,” en *Proceedings of ICML*, 2021.
- [8] A. Arnab et al., “ViViT: A Video Vision Transformer,” en *Proceedings of ICCV*, 2021.
- [9] Z. Tong et al., “VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-Training,” en *Advances in Neural Information Processing Systems*, 2022.
- [10] R. Girdhar et al., “ImageBind: One Embedding Space to Bind Them All,” en *Proceedings of CVPR*, 2023.
- [11] R. Arandjelovic y A. Zisserman, “Look, Listen and Learn,” en *Proceedings of ICCV*, 2017.
- [12] H. Sakoe y S. Chiba, “Dynamic Programming Algorithm Optimization for Spoken Word Recognition,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 26, núm. 1, 1978.
- [13] J. Lei et al., “QVHighlights: Detecting Moments and Highlights in Videos via Natural Language Queries,” en *Advances in Neural Information Processing Systems*, 2021.
- [14] A. Miech et al., “HowTo100M: Learning a Text-Video Embedding by Watching Hundred Million Narrated Video Clips,” en *Proceedings of ICCV*, 2019.