

Evaluación de sistemas multimodales

Métricas, reproducibilidad y análisis de error

Material de lectura para el curso MCC225
IA Generativa y Aprendizaje Multimodal

Semana 14

Índice

1. Propósito del documento	3
2. Contexto académico de MCC225	3
3. Problema central de la evaluación multimodal	3
3.1. Más allá de una métrica única	3
3.2. Benchmarks frente a evaluación propia	4
4. Taxonomía mínima para evaluar sistemas multimodales	4
5. Lectura de papers del Bloque A	5
5.1. HEMM: Holistic Evaluation of Multimodal Foundation Models	5
5.1.1. Uso recomendado en MCC225	5
5.2. VHELM: A Holistic Evaluation of Vision Language Models	5
5.2.1. Uso recomendado en MCC225	5
5.3. LMMs-Eval: Reality Check on the Evaluation of Large Multimodal Models	5
5.3.1. Uso recomendado en MCC225	6
5.4. VLMEvalKit: An Open-Source Toolkit for Evaluating Large Multi-Modality Models	6
5.4.1. Uso recomendado en MCC225	6
5.5. MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models	6
5.5.1. Uso recomendado en MCC225	6
5.6. MMBench: Is Your Multi-modal Model an All-around Player?	6
5.6.1. Uso recomendado en MCC225	7
5.7. MM-Vet: Evaluating Large Multimodal Models for Integrated Capabilities	7
5.7.1. Uso recomendado en MCC225	7
5.8. POPE: Evaluating Object Hallucination in Large Vision-Language Models	7
5.8.1. Uso recomendado en MCC225	7
6. Comparación metodológica de los papers	7
7. Métricas para MCC225	8
7.1. Métricas automáticas	8
7.2. Métricas humanas y rúbricas	8
7.3. LLM-as-a-judge	9
8. Reproducibilidad experimental	9
8.1. Reproducibilidad como parte de la evaluación	9
8.2. Configuración mínima	9
8.3. Checklist de trazabilidad	9
9. Análisis de error	10

9.1. Por qué el análisis de error es obligatorio	10
9.2. Matriz de errores	10
9.3. Severidad	11
10. Discusión de limitaciones	11
11. Criterios mínimos de calidad experimental	11
12. Confiabilidad y uso responsable	12
13. Propuesta de lectura para Semana 14	12
13.1. Ruta de lectura	12
13.2. Preguntas guía	12
14. Ejemplo de pipeline experimental para MCC225	13
14.1. Escenario	13
14.2. Fases	13
15. Errores conceptuales frecuentes	13
15.1. Confundir demo con evaluación	13
15.2. Reportar solo el mejor resultado	13
15.3. Usar métricas incompatibles con la tarea	13
15.4. Omitir el post-procesamiento	13
15.5. Ignorar alucinaciones	13
16. Producto esperado para el estudiante	13
17. Conclusión	14
A. Glosario breve	14

1. Propósito del documento

Este documento presenta una lectura técnica para la Semana 14 de MCC225 sobre evaluación de sistemas multimodales. El foco no está en entrenar un modelo nuevo, sino en determinar si un sistema multimodal fue evaluado con suficiente rigor para sostener una afirmación académica: que el sistema percibe, razona, recupera, responde o genera contenido multimodal de forma confiable dentro de un alcance definido.

La lectura usa ocho trabajos como eje: *HEMM*, *VHELM*, *LMMs-Eval*, *VLMEvalKit*, *MME*, *MMBench*, *MM-Vet* y *POPE*. En conjunto, estos papers permiten estudiar evaluación holística, benchmarks, herramientas reproducibles, métricas por tarea, análisis de capacidades integradas y detección de alucinación visual.

El objetivo pedagógico es que el estudiante pueda:

1. distinguir entre una demostración cualitativa y una evaluación experimental,
2. seleccionar métricas coherentes con la tarea multimodal,
3. documentar un pipeline reproducible,
4. clasificar errores por tipo y severidad,
5. discutir limitaciones sin exagerar conclusiones,
6. establecer criterios mínimos de calidad experimental.

2. Contexto académico de MCC225

MCC225 estudia sistemas que integran texto, imagen, audio y video mediante representaciones compartidas, alineamiento, fusión, transformers multimodales y modelos fundacionales. En las semanas previas, el estudiante puede haber construido notebooks o prototipos de captioning, recuperación imagen-texto, visual question answering o generación multimodal. La Semana 14 pregunta algo distinto: **cómo sabemos que el sistema funciona y bajo qué condiciones deja de funcionar.**

En multimodalidad, la evaluación es más difícil que en tareas unimodales por varias razones. Primero, las entradas pueden ser heterogéneas: una imagen con texto incrustado, una pregunta en lenguaje natural, una tabla, una escena ambigua o una secuencia de video. Segundo, la salida puede ser cerrada, abierta, textual, estructurada o generativa. Tercero, muchos sistemas combinan percepción visual con conocimiento externo y razonamiento. Por tanto, un único indicador agregado suele ocultar fallas relevantes.

Esta lectura debe entenderse como puente entre el proyecto técnico y el informe académico. Un trabajo integrador de MCC225 no debería limitarse a mostrar ejemplos exitosos; debe incluir métricas, configuración experimental, errores representativos, limitaciones, riesgos y una conclusión proporcionada al alcance de la evidencia.

3. Problema central de la evaluación multimodal

3.1. Más allá de una métrica única

Un sistema multimodal puede obtener una buena puntuación promedio y aun así fallar de manera grave en casos específicos. Por ejemplo, un modelo de VQA puede responder correctamente preguntas de conteo simples, pero fallar cuando la pregunta exige OCR, razonamiento espacial o conocimiento externo. Un modelo de captioning puede producir descripciones gramaticales, pero introducir objetos inexistentes. Un sistema de recuperación imagen-texto puede tener buen Recall@10, pero confundir sistemáticamente clases cercanas o escenas culturalmente ambiguas.

El problema central es que la evaluación debe capturar simultáneamente:

- capacidad perceptual,
- alineamiento entre modalidades,
- razonamiento composicional,
- robustez ante variaciones de prompt o entrada,
- sesgo y cobertura de datos,
- costo computacional,
- reproducibilidad,
- severidad de errores.

3.2. Benchmarks frente a evaluación propia

Los benchmarks permiten comparar modelos bajo una configuración común. Sin embargo, no sustituyen la evaluación propia del proyecto. Un benchmark puede medir una capacidad general, pero el trabajo integrador puede tener un dominio específico: imágenes médicas, material educativo, documentos, imágenes con texto, escenas urbanas, datos locales o contenido en español. La evaluación final debe combinar ambas dimensiones: referencias estandarizadas y evidencia contextual.

4. Taxonomía mínima para evaluar sistemas multimodales

Antes de escoger métricas, se debe identificar el tipo de tarea. La Tabla 1 resume una taxonomía de trabajo para MCC225.

Tabla 1: Tareas multimodales y métricas iniciales para MCC225.

Tarea	Pregunta experimental	Métricas posibles
Captioning	El texto generado describe correctamente la imagen sin inventar objetos relevantes.	BLEU, METEOR, CIDEr, SPICE, CLIPScore, evaluación humana.
Recuperación imagen-texto	El sistema recupera el texto correcto dada una imagen o la imagen correcta dado un texto.	Recall@K, MRR, mediana de ranking, mean rank.
VQA	El sistema responde una pregunta visual de forma correcta y grounded.	Accuracy, exact match normalizado, puntuación por categoría.
Clasificación multimodal	La combinación de modalidades mejora la decisión frente a una sola modalidad.	Accuracy, macro-F1, matriz de confusión, calibración.
Grounding	La respuesta se apoya en regiones o elementos visuales correctos.	IoU, pointing game, precisión de localización, inspección cualitativa.
Razonamiento visual	La solución exige contar, comparar, leer texto, ubicar objetos o combinar evidencia.	Accuracy por habilidad, análisis de errores, evaluación humana.
Generación multimodal abierta	La salida es útil, fiel, segura y adecuada al contexto.	Rúbricas, evaluación humana, juez LLM con control, análisis de riesgo.

La regla metodológica es simple: **la métrica debe corresponder al contrato de la tarea**. Si el sistema promete recuperar imágenes, se evalúa ranking. Si promete responder preguntas

visuales, se evalúa exactitud y razonamiento por categoría. Si promete explicar, se evalúa fidelidad, trazabilidad y errores de grounding.

5. Lectura de papers del Bloque A

5.1. HEMM: Holistic Evaluation of Multimodal Foundation Models

HEMM propone una evaluación holística para modelos fundacionales multimodales. Su valor para MCC225 es que no reduce la multimodalidad a una sola tarea. El paper organiza la evaluación alrededor de tres dimensiones: habilidades básicas, flujo de información y casos de uso reales. Esta estructura es especialmente útil para un curso de posgrado porque obliga a preguntar qué se evalúa realmente: alineamiento fino, razonamiento, interacción entre modalidades, traducción entre modalidades, fusión o aplicación en dominios concretos.

Para Semana 14, *HEMM* debe leerse como marco de organización. Su aporte no es solamente agregar datasets, sino mostrar que un sistema multimodal puede fallar por razones distintas: porque no alinea bien imagen y texto, porque no maneja conocimiento externo, porque no integra información temporal o porque no transfiere a un caso de uso específico.

5.1.1. Uso recomendado en MCC225

El estudiante puede usar *HEMM* para construir la sección de alcance de su informe experimental. En lugar de afirmar que un modelo es bueno en general, debe declarar que fue evaluado en ciertas habilidades, con ciertas entradas, bajo ciertas métricas y con ciertas limitaciones.

5.2. VHELM: A Holistic Evaluation of Vision Language Models

VHELM adapta la idea de evaluación holística al caso específico de modelos visión-lenguaje. Es relevante porque incorpora dimensiones que suelen omitirse en benchmarks puramente perceptuales: sesgo, fairness, multilinguismo, robustez, toxicidad y seguridad. Para MCC225, esto permite conectar evaluación técnica con confiabilidad y uso responsable.

El punto importante es que los VLMs no deben compararse solo por accuracy en una tarea visual. Dos modelos pueden estar cerca en percepción y razonamiento, pero diferir significativamente en robustez, seguridad o comportamiento ante grupos demográficos. Esa diferencia puede ser decisiva si el sistema se usa fuera de un laboratorio.

5.2.1. Uso recomendado en MCC225

VHELM puede funcionar como plantilla de criterios ampliados. Un proyecto de Semana 14 no necesita replicar VHELM completo, pero sí debe reconocer al menos algunas dimensiones: percepción, razonamiento, robustez, sesgo y seguridad. En un reporte breve, esto puede convertirse en una matriz de evaluación con resultados cuantitativos y comentarios cualitativos.

5.3. LMMs-Eval: Reality Check on the Evaluation of Large Multimodal Models

LMMs-Eval aborda un problema práctico: la evaluación de modelos multimodales grandes se ha vuelto fragmentada, costosa y difícil de reproducir. El paper propone un marco estandarizado con muchas tareas y discute una tensión importante: cobertura, costo y contaminación de benchmarks. Esta tensión es central para Semana 14.

Una evaluación con alta cobertura puede ser cara. Una evaluación barata puede ser demasiado estrecha. Una evaluación que usa benchmarks populares puede estar afectada por contaminación si los modelos han visto ejemplos similares durante entrenamiento o ajuste. Por eso el paper no solo ofrece una herramienta, sino una advertencia metodológica: la evaluación también tiene

sesgos de diseño.

5.3.1. Uso recomendado en MCC225

El estudiante debe registrar configuración, datos, versiones, comandos, número de muestras y salidas crudas. Si usa una muestra reducida, debe decirlo explícitamente. Si compara modelos, debe usar el mismo pipeline. Si usa un juez automático, debe discutir sensibilidad y posibles errores del juez.

5.4. VLMEvalKit: An Open-Source Toolkit for Evaluating Large Multi-Modality Models

VLMEvalKit es el puente más directo entre lectura y laboratorio. Su contribución es ofrecer una interfaz común para evaluar distintos modelos y benchmarks, automatizando preparación de datos, inferencia, post-procesamiento y cálculo de métricas. En un curso como MCC225, esto tiene valor porque permite pasar de discusión conceptual a práctica reproducible.

La utilidad de una herramienta de evaluación no consiste solo en ejecutar un comando. Consiste en reducir variabilidad entre evaluaciones, documentar el procedimiento y permitir que otro estudiante o revisor replique el resultado. Aun así, usar una herramienta no elimina la responsabilidad metodológica: se debe entender qué benchmark se está ejecutando, qué métrica se está reportando y qué limitaciones tiene.

5.4.1. Uso recomendado en MCC225

VLMEvalKit puede utilizarse para una actividad de comparación entre modelos visión-lenguaje. El informe debe incluir el comando, el modelo, el dataset, la versión de la herramienta, el número de muestras, las métricas, los resultados y una discusión de errores representativos.

5.5. MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models

MME es un benchmark temprano y muy influyente para evaluar MLLMs en habilidades de percepción y cognición. Su diseño busca evitar que la evaluación dependa excesivamente de prompts complejos y permite obtener estadísticas cuantitativas sobre subtareas. Para MCC225, sirve como ejemplo de evaluación por capacidades.

La distinción entre percepción y cognición es pedagógicamente útil. La percepción mide si el sistema reconoce elementos visuales, atributos o relaciones visibles. La cognición exige usar esa percepción para razonar, inferir o responder preguntas más complejas. Un error frecuente en proyectos estudiantiles es presentar ejemplos que mezclan ambas cosas sin separar el origen del fallo.

5.5.1. Uso recomendado en MCC225

Un estudiante puede imitar el espíritu de MME creando un subconjunto pequeño con preguntas de percepción y preguntas de razonamiento. La evaluación debe reportar resultados separados, no solo un promedio global.

5.6. MMBench: Is Your Multi-modal Model an All-around Player?

MMBench propone un benchmark objetivo para evaluar capacidades multimodales mediante preguntas de opción múltiple y una estrategia de evaluación circular. Su valor está en reducir ambigüedades de respuestas abiertas y facilitar comparaciones más estables entre modelos.

En modelos visión-lenguaje, la salida libre puede complicar la evaluación: dos respuestas distintas pueden ser semánticamente equivalentes, o una respuesta parcialmente correcta puede

ser difícil de puntuar. Las preguntas de opción múltiple simplifican el cálculo, pero también pueden inducir sesgos por las alternativas. MMBench muestra una forma de hacer evaluación más objetiva, aunque no elimina por completo los problemas de diseño del benchmark.

5.6.1. Uso recomendado en MCC225

Para una actividad práctica, los estudiantes pueden transformar algunas preguntas abiertas en preguntas de opción múltiple y comparar la estabilidad de las métricas. También deben discutir qué se gana y qué se pierde al cerrar el espacio de respuestas.

5.7. MM-Vet: Evaluating Large Multimodal Models for Integrated Capabilities

MM-Vet se centra en capacidades integradas. Evalúa tareas que pueden requerir reconocimiento visual, OCR, conocimiento, generación de lenguaje, razonamiento espacial y matemático. Su aporte es reconocer que muchos problemas reales no miden una habilidad aislada, sino la combinación de varias.

Este paper es clave para MCC225 porque muchos proyectos multimodales parecen simples al nivel de interfaz, pero son complejos a nivel de capacidades. Por ejemplo, responder una pregunta sobre una imagen con texto puede requerir detectar regiones, leer OCR, vincular texto con objetos, aplicar conocimiento externo y producir una explicación coherente.

5.7.1. Uso recomendado en MCC225

El estudiante debe etiquetar cada caso de prueba con las capacidades requeridas. Cuando el modelo falla, la matriz de error debe indicar si el fallo fue perceptual, de OCR, de conocimiento, espacial, matemático, lingüístico o de integración.

5.8. POPE: Evaluating Object Hallucination in Large Vision-Language Models

POPE estudia la alucinación de objetos en modelos visión-lenguaje. El problema aparece cuando el modelo menciona objetos que no están presentes en la imagen. Esta falla es especialmente peligrosa porque una respuesta fluida puede parecer confiable aunque no esté grounded en la evidencia visual.

El método POPE propone consultas tipo sondeo para evaluar si el modelo afirma la presencia de objetos. Para Semana 14, el paper es fundamental porque conecta evaluación con confiabilidad: no basta con que el modelo produzca una respuesta plausible; debe evitar inventar elementos visuales.

5.8.1. Uso recomendado en MCC225

En un proyecto de captioning o VQA, el estudiante debe incluir un análisis de alucinación. Esto puede hacerse revisando objetos mencionados frente a la imagen, clasificando falsos positivos visuales y separando errores de omisión de errores de invención.

6. Comparación metodológica de los papers

La Tabla 2 organiza los ocho trabajos como piezas complementarias de una misma metodología de evaluación.

Tabla 2: Lectura comparada de papers para Semana 14.

Paper	Pregunta que ayuda a responder	Aporte principal	Uso en MCC225
HEMM	Qué significa evaluar holísticamente un modelo multimodal.	Dimensiones de habilidades, flujo de información y casos de uso.	Marco conceptual del informe.
VHELM	Cómo evaluar VLMs considerando riesgo y comportamiento amplio.	Aspectos como percepción, conocimiento, razonamiento, sesgo, robustez, toxicidad y seguridad.	Criterios ampliados de calidad.
LMMs-Eval	Cómo hacer evaluación estandarizada y reproducible a bajo costo.	Framework con muchas tareas y discusión de cobertura, costo y contaminación.	Checklist de reproducibilidad.
VLMEvalKit	Cómo operacionalizar evaluaciones con herramientas comunes.	Toolkit para modelos y benchmarks multimodales.	Práctica de laboratorio.
MME	Cómo separar percepción y cognición en MLLMs.	Benchmark con subtas de capacidades.	Evaluación por grupos de habilidad.
MMBench	Cómo hacer evaluación objetiva y comparable en VLMs.	Opción múltiple, evaluación circular y pipeline robusto.	Diseño de preguntas controladas.
MM-Vet	Cómo medir capacidades integradas.	Combinación de reconocimiento, OCR, conocimiento, lenguaje, espacialidad y matemática.	Matriz de capacidades requeridas.
POPE	Cómo medir alucinación de objetos.	Sondeo de presencia de objetos y análisis de falsos positivos.	Análisis de grounding y confiabilidad.

7. Métricas para MCC225

7.1. Métricas automáticas

Las métricas automáticas son necesarias porque permiten comparar configuraciones, repetir experimentos y detectar cambios de desempeño. Sin embargo, no deben interpretarse sin contexto.

En captioning, BLEU y ROUGE capturan coincidencia superficial con referencias; CIDEr y SPICE intentan aproximarse mejor a contenido semántico; CLIPScore usa compatibilidad imagen-texto. En recuperación, Recall@K y MRR miden ranking. En VQA, exact match o accuracy dependen de normalización de respuestas. En clasificación, macro-F1 puede ser más informativo que accuracy cuando hay clases desbalanceadas.

7.2. Métricas humanas y rúbricas

Las métricas humanas siguen siendo importantes cuando la salida es abierta. Una rúbrica mínima para MCC225 puede usar cuatro dimensiones:

1. **Corrección:** la respuesta coincide con la evidencia disponible.
2. **Compleitud:** la respuesta cubre lo necesario sin omisiones importantes.

3. **Grounding**: la respuesta se apoya en la imagen, texto, audio o video de entrada.
4. **Seguridad**: la respuesta evita afirmaciones no justificadas o riesgos de uso indebido.

7.3. LLM-as-a-judge

El uso de modelos como jueces puede acelerar evaluaciones abiertas, pero debe documentarse como una fuente adicional de incertidumbre. El juez puede tener sesgos, variar con el prompt, favorecer respuestas más largas o penalizar estilos válidos. En Semana 14, si se usa LLM-as-a-judge, se recomienda reportar el prompt del juez, ejemplos auditados manualmente y casos de desacuerdo.

8. Reproducibilidad experimental

8.1. Reproducibilidad como parte de la evaluación

Una evaluación no es reproducible solo porque el código se pueda ejecutar. Debe existir trazabilidad suficiente para que otra persona reconstruya el experimento. En modelos multimodales esto incluye datos, prompts, preprocesamiento, versiones de modelos, librerías, hardware, semillas, número de muestras, costo, métricas, post-procesamiento y salidas crudas.

8.2. Configuración mínima

Listing 1: Archivo mínimo de configuración para una evaluación multimodal.

```
experiment:
  name: semana14_vlm_eval
  seed: 123
  task: visual_question_answering
  model: modelo_vlm_base
  model_version: v1
  dataset: subconjunto_mcc225
  split: test
  num_samples: 200
  prompt_template: prompts/vqa_es.txt
  metrics:
    - exact_match
    - accuracy_by_category
    - hallucination_rate
  outputs:
    raw_predictions: results/predictions.jsonl
    summary: results/summary.json
    error_matrix: results/errors.csv
runtime:
  python: 3.11
  device: cuda
  gpu: RTX_4080_SUPER
  batch_size: 8
```

8.3. Checklist de trazabilidad

Tabla 3: Checklist mínimo de reproducibilidad para Semana 14.

Elemento	Debe reportarse
Modelo	Nombre, versión, checkpoint, configuración de inferencia.

Elemento	Debe reportarse
Datos	Fuente, partición, número de muestras, criterios de filtrado.
Prompts	Plantillas completas, idioma, instrucciones del sistema si existen.
Preprocesamiento	Resolución de imagen, normalización, OCR, tokenización, truncamiento.
Métricas	Fórmula o definición operativa, script usado, post-procesamiento.
Hardware	CPU, GPU, memoria, entorno local o cluster.
Software	Python, librerías, commit del repositorio, versión del tool-kit.
Aleatoriedad	Semillas, muestreo, temperatura, top-p, beam search si aplica.
Salidas	Predicciones crudas, resultados agregados, logs y matriz de errores.
Limitaciones	Alcance, sesgos, amenazas a la validez y costo.

9. Análisis de error

9.1. Por qué el análisis de error es obligatorio

El promedio no explica el comportamiento del sistema. El análisis de error permite identificar patrones: fallas por OCR, alucinaciones, sesgos culturales, dependencia del prompt, errores de localización, confusiones semánticas o falta de conocimiento. En MCC225, una evaluación sin análisis de error debe considerarse incompleta.

9.2. Matriz de errores

Tabla 4: Categorías sugeridas para la matriz de errores.

Categoría	Descripción	Evidencia esperada
Error perceptual	El modelo no reconoce un objeto, atributo, acción o relación visible.	Imagen, pregunta, respuesta, region relevante.
Error de OCR	El texto visible no se lee o se interpreta mal.	Recorte o transcripción esperada.
Error espacial	El modelo falla en posiciones, direcciones, conteo o relaciones geométricas.	Explicación de la relación correcta.
Error de conocimiento	La imagen requiere conocimiento externo que el modelo no usa bien.	Fuente o razonamiento esperado.
Alucinación visual	El modelo menciona objetos o hechos no presentes.	Lista de objetos inventados.
Error de grounding	La respuesta no se apoya en evidencia de entrada.	Contraste entre salida y entrada.
Error de prompt	La respuesta cambia por sensibilidad a la formulación.	Variantes de prompt y salidas.
Sesgo de datos	El error afecta sistemáticamente un grupo, idioma o contexto.	Subconjunto afectado.
Error de evaluación	La métrica penaliza o acepta indebidamente una respuesta.	Caso auditado manualmente.

Categoría	Descripción	Evidencia esperada
Fuera de distribución	El ejemplo no se parece a los datos esperados por el modelo.	Descripción del cambio de dominio.

9.3. Severidad

No todos los errores tienen el mismo impacto. Se recomienda clasificar severidad en tres niveles:

- **Baja:** afecta estilo o detalle menor sin cambiar la conclusión.
- **Media:** produce una respuesta incompleta o parcialmente incorrecta.
- **Alta:** inventa evidencia, induce decisión equivocada o contradice la entrada.

10. Discusión de limitaciones

Una buena discusión de limitaciones protege la calidad académica del informe. No es una sección decorativa; es parte de la evidencia. En modelos multimodales, las limitaciones más comunes son:

1. muestra de evaluación pequeña,
2. sesgo de idioma o dominio,
3. dependencia de prompts,
4. falta de auditoria humana,
5. métrica incompleta,
6. contaminación potencial de benchmarks,
7. costo que impide repetir experimentos,
8. ausencia de análisis por subgrupos,
9. falta de evaluación fuera de distribución,
10. uso de modelos propietarios sin control total de versión.

La conclusión debe ser proporcional. Si el experimento usa 100 ejemplos, no se debe afirmar que el sistema es robusto en general. Si solo se evalúa en imágenes limpias, no se debe extrapolar a imágenes ruidosas. Si se usa un benchmark en inglés, no se debe afirmar desempeño equivalente en español.

11. Criterios mínimos de calidad experimental

Para Semana 14, un informe aceptable debe cumplir los criterios de la Tabla 5.

Tabla 5: Criterios mínimos de calidad experimental para MCC225.

Criterio	Estandar mínimo
Pregunta experimental	Debe ser específica y evaluable.
Tarea definida	Debe quedar claro si es captioning, retrieval, VQA, grounding u otra tarea.
Datos documentados	Debe indicarse fuente, tamaño, partición y criterio de selección.
Métricas justificadas	Cada métrica debe relacionarse con la tarea.
Baseline	Debe existir una referencia simple o modelo comparativo si es posible.

Criterio	Estandar mínimo
Resultados cuantitativos	Deben presentarse tablas o agregados verificables.
Errores cualitativos	Deben analizarse casos correctos e incorrectos.
Reproducibilidad	Deben guardarse comandos, versiones, configuración y salidas.
Limitaciones	Deben discutirse alcance, sesgo, costo y amenazas a la validez.
Responsabilidad	Deben declararse riesgos de uso, supervisión humana y comunicación de incertidumbre.

12. Confiabilidad y uso responsable

Aunque este bloque se concentra en evaluación, métricas y reproducibilidad, la confiabilidad no puede separarse de la evaluación. Un sistema multimodal confiable debe comportarse de forma estable dentro de su alcance, reconocer incertidumbre, evitar alucinaciones críticas y no ocultar limitaciones.

En MCC225, el uso responsable puede formularse como cuatro preguntas:

1. Qué afirmaciones están justificadas por la evidencia experimental.
2. Qué afirmaciones no deberían hacerse con los datos disponibles.
3. Qué errores podrían afectar usuarios o decisiones.
4. Qué supervisión humana o advertencias necesita el sistema.

Un informe responsable no presenta el modelo como autoridad absoluta. Presenta resultados, condiciones, errores, restricciones y riesgos.

13. Propuesta de lectura para Semana 14

13.1. Ruta de lectura

Se recomienda leer los papers en el siguiente orden:

1. *HEMM*, para entender evaluación holística.
2. *VHELM*, para ampliar la evaluación a aspectos de riesgo.
3. *MME* y *MMBench*, para estudiar benchmarks de capacidades y comparación objetiva.
4. *MM-Vet*, para analizar capacidades integradas.
5. *POPE*, para estudiar alucinación visual.
6. *LMMs-Eval* y *VLMEvalKit*, para conectar evaluación con herramientas reproducibles.

13.2. Preguntas guía

1. Qué entiende cada paper por evaluación multimodal.
2. Qué capacidades mide y cuáles deja fuera.
3. Qué tipo de salida evalúa: cerrada, abierta, ranking o generativa.
4. Qué métricas usa y qué supuestos hacen esas métricas.
5. Cómo controla prompt, post-procesamiento y comparabilidad.
6. Qué riesgos de contaminación, sesgo o costo reconoce.
7. Cómo podría adaptarse al trabajo integrador de MCC225.

14. Ejemplo de pipeline experimental para MCC225

14.1. Escenario

Considere un proyecto que evalúa un modelo visión-lenguaje para responder preguntas sobre material educativo con imágenes, diagramas y texto incrustado. El objetivo no es solo obtener accuracy, sino entender qué tipos de preguntas resuelve y dónde falla.

14.2. Fases

1. Definir categorías: percepción, OCR, razonamiento espacial, conocimiento y explicación.
2. Construir un subconjunto de evaluación balanceado por categoría.
3. Ejecutar el modelo con prompts fijos y temperatura controlada.
4. Guardar predicciones crudas en JSONL.
5. Calcular exact match o accuracy normalizado.
6. Separar resultados por categoría.
7. Auditar manualmente al menos 20 errores.
8. Clasificar errores en la matriz propuesta.
9. Redactar limitaciones y amenazas a la validez.
10. Concluir solo dentro del alcance de la evidencia.

15. Errores conceptuales frecuentes

15.1. Confundir demo con evaluación

Mostrar cinco ejemplos exitosos no prueba desempeño. Una demo sirve para ilustrar, pero una evaluación requiere datos, procedimiento, métrica y análisis de errores.

15.2. Reportar solo el mejor resultado

Seleccionar únicamente el resultado más favorable genera una imagen incompleta. Se deben reportar configuraciones probadas, fallas y decisiones de filtrado.

15.3. Usar métricas incompatibles con la tarea

No tiene sentido evaluar una tarea de ranking solo con accuracy, ni una salida abierta solo con coincidencia exacta sin normalización o rúbrica.

15.4. Omitir el post-procesamiento

En VQA y benchmarks de opción múltiple, el post-procesamiento puede cambiar el resultado. Debe registrarse como parte del pipeline.

15.5. Ignorar alucinaciones

En sistemas multimodales, inventar objetos o relaciones puede ser más grave que omitir detalles. POPE debe leerse precisamente como advertencia contra la fluidez no grounded.

16. Producto esperado para el estudiante

Al finalizar Semana 14, el estudiante debería entregar una lectura aplicada o mini-informe con la siguiente estructura:

1. problema y tarea,
2. modelo evaluado,
3. datos y partición,
4. métricas y justificación,
5. configuración reproducible,
6. resultados cuantitativos,
7. análisis de errores,
8. discusión de limitaciones,
9. riesgos de confiabilidad y uso responsable,
10. conclusión.

17. Conclusión

La evaluación de sistemas multimodales es una actividad metodológica central, no un trámite final. Los papers revisados muestran que la calidad de un sistema no puede resumirse en un único número. HEMM y VHELM aportan una visión holística; MME, MMBench y MM-Vet organizan la evaluación por capacidades; POPE visibiliza el problema de alucinación visual; LMMs-Eval y VLMEvalKit conectan la discusión con herramientas reproducibles.

Para MCC225, la conclusión principal es que un proyecto multimodal debe evaluarse con la misma seriedad con la que se implementa. Un buen informe no solo muestra que el modelo acierta; también explica cuándo falla, por qué falla, cuánto cuesta verificarlo, qué se puede reproducir y qué afirmaciones todavía no están justificadas.

A. Glosario breve

Alucinación visual: afirmación sobre objetos, atributos o relaciones que no están presentes en la entrada visual.

Benchmark: conjunto de datos, protocolo y métrica usados para comparar sistemas bajo condiciones comunes.

Contaminación de benchmark: posibilidad de que ejemplos de evaluación o datos muy similares hayan aparecido durante entrenamiento, ajuste o selección del modelo.

Grounding: relación verificable entre una salida del modelo y evidencia presente en las modalidades de entrada.

LLM-as-a-judge: uso de un modelo de lenguaje para puntuar o comparar respuestas generadas por otro sistema.

Macro-F1: promedio de F1 calculado por clase, útil cuando hay desbalance.

MRR: mean reciprocal rank, métrica de ranking que recompensa ubicar la respuesta correcta en posiciones altas.

Recall@K: proporción de consultas donde el elemento correcto aparece entre los primeros K resultados.

Reproducibilidad: capacidad de reconstruir una evaluación a partir de código, datos, configuración, versiones y salidas documentadas.

Robustez: estabilidad del comportamiento ante perturbaciones razonables de entrada, prompt, formato o dominio.

Referencias

- [1] Liang, P. P., Goindani, A., Chafekar, T., Mathur, L., Yu, H., Salakhutdinov, R., y Morency, L.-P. *HEMM: Holistic Evaluation of Multimodal Foundation Models*. arXiv:2407.03418, 2024. <https://arxiv.org/abs/2407.03418>
- [2] Lee, T., Tu, H., Wong, C. H., Zheng, W., Zhou, Y., Mai, Y., Roberts, J. S., Yasunaga, M., Yao, H., Xie, C., y Liang, P. *VHELM: A Holistic Evaluation of Vision Language Models*. arXiv:2410.07112, 2024. <https://arxiv.org/abs/2410.07112>
- [3] Zhang, K., Li, B., Zhang, P., Pu, F., Cahyono, J. A., Hu, K., Liu, S., Zhang, Y., Yang, J., Li, C., y Liu, Z. *LMMs-Eval: Reality Check on the Evaluation of Large Multimodal Models*. arXiv:2407.12772, 2024. <https://arxiv.org/abs/2407.12772>
- [4] Duan, H., Yang, J., Qiao, Y., Fang, X., Chen, L., Liu, Y., Agarwal, A., Chen, Z., Li, M., Ma, Y., Sun, H., Zhao, X., Cui, J., Dong, X., Zang, Y., Zhang, P., Wang, J., y Chen, K. *VLMEvalKit: An Open-Source Toolkit for Evaluating Large Multi-Modality Models*. arXiv:2407.11691, 2024. <https://arxiv.org/abs/2407.11691>
- [5] Fu, C., Chen, P., Shen, Y., Qin, Y., Zhang, M., Lin, X., Yang, J., Zheng, X., Li, K., Sun, X., Wu, Y., y Ji, R. *MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models*. arXiv:2306.13394, 2023. <https://arxiv.org/abs/2306.13394>
- [6] Liu, Y., Duan, H., Zhang, Y., Li, B., Zhang, S., Zhao, W., Yuan, Y., Wang, J., He, C., Liu, Z., Chen, K., y Lin, D. *MMBench: Is Your Multi-modal Model an All-around Player?* arXiv:2307.06281, 2023. <https://arxiv.org/abs/2307.06281>
- [7] Yu, W., Yang, Z., Li, L., Wang, J., Lin, K., Liu, Z., Wang, X., y Wang, L. *MM-Vet: Evaluating Large Multimodal Models for Integrated Capabilities*. arXiv:2308.02490, 2023. <https://arxiv.org/abs/2308.02490>
- [8] Li, Y., Du, Y., Zhou, K., Wang, J., Zhao, W. X., y Wen, J.-R. *Evaluating Object Hallucination in Large Vision-Language Models*. arXiv:2305.10355, 2023. <https://arxiv.org/abs/2305.10355>